

4/23 미팅
MUSE 및 ACTMED 계산 방식 정리

하서준

DGIST

April 23, 2026

INITIALIZATION

환자 노드 $i = 1, \dots, B$

$$\mathbf{h}_i^{(0)} = \mathbf{1} \in \mathbb{R}^d$$

모든 값이 1인 상수 벡터 ($d = 128$). 직접 학습되지 않음.
Message passing 및 노드 update 과정에서 값이 갱신됨.
최종 노드 임베딩이 classification에 사용됨.

Modality 노드 $m \in \{1, 2, 3\}$

$$\mathbf{h}_m^{(0)} = \boldsymbol{\theta}_m \in \mathbb{R}^d, \quad \boldsymbol{\theta}_m \sim \mathcal{N}(0, 1)$$


Modality 유형별로 하나의 학습 가능한 벡터. 모든 환자에서 공유됨.
“이 modality가 어떤 종류인가”를 표현함.

(논문: $\text{OneHot}(m) \in \mathbb{R}^3$; 코드: $\text{nn.Parameter} \in \mathbb{R}^{128}$)

Edge 속성 (환자 $i \leftrightarrow$ modality m)

$$\mathbf{e}_{im}^{(0)} = f_m(\mathbf{x}_i) \in \mathbb{R}^d$$

Modality별 인코더 f_m (FFN / RNN / Transformer)의 출력값.
환자 i 가 modality m 을 보유한 경우($\text{flag}_{im} = 1$)에만 edge 존재.
양방향 초기값 동일: $\mathbf{e}_{im}^{(0)} = \mathbf{e}_{mi}^{(0)}$ (repeat(2, 1)).



MESSAGE PASSING (1 HOP)

1. Message 생성 ($d \rightarrow d$)

$$\text{msg}_{j \rightarrow i}^{(l)} = \text{ReLU}\left(\mathbf{W}^{(l)} \mathbf{h}_j^{(l-1)} + \mathbf{O}^{(l)} \mathbf{e}_{ji}^{(l-1)}\right) \in \mathbb{R}^d$$

Edge마다 독립적으로 message 생성:

송신 노드 $\mathbf{h}_j$ + 해당 edge 속성 $\mathbf{e}_{ji} \rightarrow \text{concat} \rightarrow \text{Linear} \rightarrow \text{ReLU}$.

2. Aggregation ($d \rightarrow d$)

$$\mathbf{a}_i^{(l)} = \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \text{msg}_{j \rightarrow i}^{(l)} \in \mathbb{R}^d$$


이웃 $\mathcal{N}(i)$ 로부터 수신된 message를 mean pooling.

연결 구조에 따라 수신 message 수가 달라지며,
집계값은 다음 node update의 입력으로 사용됨.

3. Update ($2d \rightarrow d$, Eq. 7)

$$\mathbf{h}_i^{(l)} = \text{ReLU}\left(\mathbf{U}^{(l)} \underbrace{\text{Concat}\left(\mathbf{h}_i^{(l-1)}, \mathbf{a}_i^{(l)}\right)}_{\in \mathbb{R}^{2d}}\right) \in \mathbb{R}^d$$

이전 자신의 임베딩 + aggregated 이웃 정보를 결합. **모든 노드에 동시에, 양방향으로** 적용됨.



1-hop: 연결된 이웃으로부터 message를 수신하고 집계

2-hop: 갱신된 노드/edge 상태로 동일 연산을 반복

단일 환자 추론에서도 동일한 계산 흐름

EDGE UPDATE

각 hop 완료 후 (마지막 hop 제외), 모든 edge 속성 갱신:


$$\mathbf{e}_{ji}^{(l)} = \text{ReLU} \left(\underbrace{\mathbf{P}^{(l)} \text{Concat} \left(\mathbf{h}_j^{(l)}, \mathbf{h}_i^{(l)}, \mathbf{e}_{ji}^{(l-1)} \right)}_{\in \mathbb{R}^{3d}} \right) \in \mathbb{R}^d$$

업데이트된 송신/수신 노드 임베딩 $\mathbf{h}_j^{(l)}, \mathbf{h}_i^{(l)}$ 과 이전 edge 속성 $\mathbf{e}_{ji}^{(l-1)}$ 을 concat하여 새 edge 속성 생성.

- ▶ 방향이 바뀌면 concat 입력의 송신/수신 순서도 달라짐

$$\text{Concat}(\mathbf{h}_j^{(l)}, \mathbf{h}_i^{(l)}, \mathbf{e}_{ji}^{(l-1)})$$

- ▶ 갱신된 edge 속성은 다음 hop의 message 생성에 입력으로 사용됨



반대 방향에 대해
각각 별도의 edge 벡터 존재

초기 (hop 0): 양방향 edge에 동일한
modality encoder 출력 사용

edge update 이후: 방향별 입력 순서에 따
라 별도 edge state 유지

MUSE의 MODALITY ENCODER

Modality	입력	Encoder	출력
의료 코드	ICD 진단/시술/ 처방 코드 ID	Transformer (처음부터 학습)	128차원
검사 수치	114개 검사 항목 시계열 데이터	양방향 GRU	128차원
임상 노트	퇴원 요약문	Bio_ClinicalBERT (frozen)	128차원

주요 설계 선택


- ▶ 코드 임베딩은 Bio_ClinicalBERT로 인코딩된 코드 설명으로 초기화 (frozen lookup)
- ▶ 임상 노트 encoder는 완전히 frozen; 코드 Transformer는 end-to-end로 fine-tuning
- ▶ 모든 modality는 GNN 입력 전에 동일한 128차원 공간으로 투영됨

BATCH 크기에 따라 BIPARTITE GRAPH 크기 변화

Batch당 그래프 구조

- ▶ 환자 노드: B 개 (= batch 크기)
- ▶ Modality 노드: 3개 (고정)
- ▶ Edge: 최대 $3B$ 개 (보유 modality당 1개)

Batch 크기 = 1 $\Rightarrow$ 환자 노드 1개
Batch 크기 = 512 $\Rightarrow$ 환자 노드 512개
Modality 노드는 항상 3개 고정
 $\therefore$ Batch 크기에 따라 graph 크기와
modality 노드의 aggregation 대상 수가
달라짐



EXPERIMENT : BATCH 크기가 추론 성능에 미치는 영향

batch_size = 512				
All present	(C+L+N)	(n=19094):	AUROC=0.8585	PR-AUC=0.5143
Missing lab	(C+N)	(n=1121):	AUROC=0.9194	PR-AUC=0.6741
Missing note	(C+L)	(n=6744):	AUROC=0.8773	PR-AUC=0.4529
Missing lab+note	(C)	(n=4276):	AUROC=0.8213	PR-AUC=0.2924
ALL patients		(n=31235):	AUROC=0.8698	PR-AUC=0.4909
100%				
batch_size = 1				
All present	(C+L+N)	(n=19094):	AUROC=0.8585	PR-AUC=0.5143
Missing lab	(C+N)	(n=1121):	AUROC=0.9194	PR-AUC=0.6747
Missing note	(C+L)	(n=6744):	AUROC=0.8773	PR-AUC=0.4529
Missing lab+note	(C)	(n=4276):	AUROC=0.8214	PR-AUC=0.2927
ALL patients		(n=31235):	AUROC=0.8698	PR-AUC=0.4909
Delta: batch_N - batch_1 (양수 = batch_N이 유리)				
All present	(n=19094):	Δ AUROC=+0.0000	Δ PR-AUC=-0.0000	
Missing lab	(n= 1121):	Δ AUROC=-0.0000	Δ PR-AUC=-0.0006	
Missing note	(n= 6744):	Δ AUROC=-0.0000	Δ PR-AUC=+0.0000	
Missing both	(n= 4276):	Δ AUROC=-0.0001	Δ PR-AUC=-0.0003	
ALL	(n=31235):	Δ AUROC=+0.0000	Δ PR-AUC=-0.0000	

Figure. Batch 크기에 따른 테스트셋 성능 (MIMIC-IV, 사망률 예측)

- ▶ 동일한 checkpoint에서 batch 크기 512 vs. 1 비교 시 Δ AUROC $\approx$ 0.000, Δ PR-AUC $\approx$ 0.000 (모든 modality 누락 그룹에서 동일)
- ▶ **원인:** 환자 노드가 동일한 $1 \in \mathbb{R}^d$ 로 초기화되므로, 환자들이 modality 노드로 보내는 message는 edge 속성 e_{im} 의 batch 평균으로 수렴함. Batch 크기가 달라도 이 평균의 차이가 미미하여 환자별 예측 순위에 영향을 주지 못함. (AUROC는 순위 기반 지표)
- ▶ MUSE는 단일 환자 추론 환경에서도 **성능 저하 없음** $\Rightarrow$ 임상 배포 적합성 확인

ACTMED

Active Test Selection for Timely Clinical Diagnosis

Bayesian Experimental Design + LLM

현실에서의 임상 진단

진단은 정적 분류가 아님

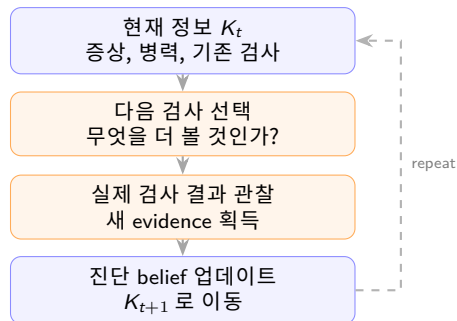
- ▶ 진단은 본질적으로 **순차적**이고 **단계적**
- ▶ 환자 정보가 한 번에 모두 주어지지 않음
- ▶ 새 검사 결과에 따라 다음 판단이 계속 바뀜

검사는 공짜가 아님

- ▶ 검사마다 비용, 시간, 환자 부담 발생
- ▶ 불필요한 검사가 전체의 **40-60%**로 추정
- ▶ WHO: 2035년까지 의료인력 **1,200만 명** 부족

동적 진단

현재 정보에 따라 검사 선택과 belief 업데이트를 반복



핵심 문제

정확한 진단뿐 아니라, **어떤 검사를 언제 시행할지**를 환자별로 결정해야 함.

기존 방법의 한계

기존 방법의 전형적 한계

방법	순차적	개인 맞춤	투명성
Rule-based	×	×	✓
Classical ML	×	×	×
Deep Learning	×	×	×
Naïve LLM	✓	×	×
ACTMED	✓	✓	✓

대부분의 기존 방법은 위 세 가지 중 하나 이상을 충족하지 못함.

비교 대상 간단 정리

Rule-based: 설명 가능, 개인화/순차성 약함

Classical ML / Deep Learning: 전체 feature가 있다고 가정

Naïve LLM: 직접 추천 가능, 선택 기준 불명확

ACTMED: 순차적·개인맞춤·투명한 검사 선택

정적 ML 가정의 문제

기존 ML 모델은 모든 데이터가 주어진다고 가정하고 진단을 정적 분류 문제로 다룸.

실제 임상 추론의 순차적·자원 인식적 특성을 반영하기 어려움.


Naïve LLM의 문제

- ▶ 확률적 추론이 약함
- ▶ 모든 환자에게 동일한 검사 추천 (개인화 불가)
- ▶ 블랙박스: 추론 과정 불투명

필요한 조건

- ▶ 환자별 현재 정보에 따라 다음 검사를 선택
- ▶ 검사 비용을 고려한 정보 획득 기준
- ▶ 선택 과정이 임상 의에게 설명 가능

아이디어 (FIGURE 2)



순차적 진단으로 재정의

진단을 한 번의 분류 문제가 아니라, 현재 정보 K_t 에서 **다음 검사를 고르는** 의사결정 문제로 다룸.

ACTMED는 영상/텍스트/혈액 같은 modality 선택이 아니라, 관측할 **검사 항목(feature)**을 고르는 Active Feature Acquisition 문제.

각 검사별 기대 정보량 계산

각 후보 검사를 시행했을 때 진단 belief가 얼마나 바뀔지 미리 추정하고, 비용 대비 변화량이 큰 검사를 선택.

LLM을 서로게이트로 활용

복잡한 의료 분포를 직접 모델링하지 않고, LLM이 prior, 가상 검사 결과, posterior를 추정하도록 사용.

LLM의 역할: 서로게이트 샘플러

왜 수식 모델이 아닌가?

공학/물리학에서 BED는 닫힌 형태의 수식 사용.

의료에서는: 생리학적 변수들이 **비선형**, **고차원**, **부분 관측** $\Rightarrow$ 직접 모델링 불가.

LLM을 서로게이트로

LLM은 대규모 의학 문헌에서 의학 지식을 학습.

K_t 를 프롬프트로 받아 **조건부 샘플러**처럼 작동:

$$u_t^{(i,j)} \sim P(U_t^{(i)} | K_t)$$

현재 정보 K_t 가 주어졌을 때, 후보 검사 i 의 가능한 j 번째 결과를 샘플링한다는 의미.

환각(Hallucination) 완화

1. 구조화된 임상 요약문(vignette) 프롬프트
2. 가능한 검사 결과를 하나로 고정하지 않고 **여러 후보값으로 샘플링**
3. 질병 있음/없음 **양쪽 모두** 고려하도록 지시 — 한쪽 진단으로 성급히 고정되는 것을 완화

LLM이 하는 세 가지

역할	출력
Prior 추정	$p_{\text{prior}} \in [0, 1]$
검사 결과 생성	$u_t^{(i,j)} \in \mathbb{R}$
Posterior 추정	$p_{\text{post}} \in [0, 1]$

검사 utility 계산

$$\mathbb{E}[\text{KL}] = \frac{1}{M} \sum_{j=1}^M \left[p_{\text{post}}^{(j)} \log \frac{p_{\text{post}}^{(j)}}{p_{\text{prior}}} + (1 - p_{\text{post}}^{(j)}) \log \frac{1 - p_{\text{post}}^{(j)}}{1 - p_{\text{prior}}} \right]$$

각 샘플별 prior-posterior 변화량을 KL로 계산한 뒤 평균낸 값.

주의

프레임워크 품질은 **LLM 품질에 완전 종속**.
GPT-4o급 필요; 작은 모델은 실패.

핵심 아이디어

핵심 아이디어

Bayesian Experimental Design (BED) + LLM
을 결합하여 실제 임상 추론을 모방.

LLM의 강점(의학 지식)으로 검사 결과를
시뮬레이션하고,
BED의 수학적 엄밀성으로 최적 검사를 선택.

베이지안 실험 설계

“비용 대비 가장 많은 정보를 주는 검사는?”

$$F(U_t^{(i)}) = \frac{\mathbb{E}[\text{KL}(\mathbb{B}(p_{\text{post}}) || \mathbb{B}(p_{\text{prior}}))]}{c(U_t^{(i)})}$$

비용 대비 정보량이 가장 큰 검사를 선택.

LLM의 역할

- ▶ 단순 classifier로 바로 쓰는 것이 아님
- ▶ 핵심 역할은 **검사 선택을 위한 서로게이트**
- ▶ $u_t^{(i,j)} \sim P(U_t^{(i)} | K_t)$ — 태스크별 학습 불필요


ACTMED selects the next diagnostic test at each time step t



핵심 포인트

LLM은 검사 선택 과정에서 **prior**, 후보 검사 결과, **posterior**를 추정하는 서로게이트이고, 선택 자체는 기대 KL divergence를 비용으로 정규화한 $F(U_t^{(i)})$ 로 결정된다.

POSTERIOR 기반 검사 선택 기준 (FIGURE 1)



1. Prior belief

현재 정보 K_t 만으로 질병 risk p_{prior} 를 먼저 추정.

아직 새 검사를 보기 전의 현재 믿음.

2. Posterior samples

후보 검사마다 결과를 $M = 10$ 번 시뮬레이션하고, 각 결과별 $p_{\text{post}}^{(j)}$ 를 추정.

각 검사별 가능한 결과 10개를 만들고, posterior 변화량을 평균.

3. Utility

$$F(U_t^{(j)}) = \frac{\mathbb{E}[\text{KL}(\mathbb{B}(p_{\text{post}}) \parallel \mathbb{B}(p_{\text{prior}}))]}{c(U_t^{(j)})}$$

평균 belief 변화량 / 비용이
가장 큰 검사를 선택.

불확실성 감소보다 “진단 확률이 얼마나 바뀌는가”를 우선.

Figure 1은 Bernoulli PMF가 아니라, 후보 검사별 posterior risk가 prior에서 얼마나 이동하는지를 보여주는 개념도.

실험 설정

데이터셋

데이터셋	태스크	환자 수
CKD	신장 질환	157
Hepatitis	C형 간염	112
Diabetes	당뇨	100
OSCE	다중 질환	114×2*

* 실제 케이스 + 합성 음성 대조군
모두 이진 분류, 구조화된 혈액 검사값만 사용
⇒ **Active Feature Acquisition** 설정

실험 조건

- ▶ 환자당 최대 **검사 3개** 제한
- ▶ 모든 검사 비용 동일 가정
- ▶ 5개 랜덤 시드, 평균 ± 표준편차 보고

비교 대상 (Baselines)

방법	설명
All Features	제한 없이 전체 사용 (상한)
Random	3개 무작위 선택
Global Best	환자 정보 전, 전역 최적 3개 고정
Implicit	BED 없이 LLM이 직접 선택
ACTMED	BED + LLM (제안)

사용 모델

- ▶ GPT-4o
- ▶ GPT-4o-mini
- ▶ BioMistral-7B (실패 사례)
- ▶ LLaMA-70B (실패 사례)

실험 결과 1: LLM 샘플링 품질 (SECTION 4.1)

4.1절의 질문

LLM이 실제 임상 검사값 분포를 그럴듯하게 생성할 수 있는가?

평가 방식

- ▶ 환자별 현재 정보 K_i 를 조건으로 사용
- ▶ 누락된 각 검사 항목에 대해 plausible outcome 10개 샘플링
- ▶ 생성 분포와 실제 데이터 분포를 비교
- ▶ 지표: Wasserstein distance, Energy distance

해석

값이 낮을수록 실제 검사값 분포와 유사함.


⇒ LLM이 BED의 surrogate sampler로 쓸 수 있는지 검증.

Table 1: *Normalized distribution matching metrics (lower is better). Average Wasserstein and Energy Distance (mean $\pm$ std).*

Dataset	Model	Wasserstein	Energy
Diabetes	GPT-4o	0.110 ± 0.038	0.256 ± 0.079
	GPT-4o-mini	0.117 ± 0.046	0.269 ± 0.094
Hepatitis	GPT-4o	0.130 ± 0.157	0.265 ± 0.191
	GPT-4o-mini	0.173 ± 0.237	0.330 ± 0.254
Kidney	GPT-4o	0.082 ± 0.055	0.203 ± 0.102
	GPT-4o-mini	0.082 ± 0.057	0.203 ± 0.104

GPT-4o와 GPT-4o-mini 모두 비교적 낮은 distance를 보여, 후보 검사 결과 샘플링이 실제 분포와 크게 어긋나지 않음을 확인.

실험 결과 2: 진단 정확도



비교 설정

방법	설정
All Features	사용 가능한 모든 검사 항목을 관측한 상한선 설정
Random	후보 검사 중 최대 3개를 무작위로 선택
Global Best	환자별 정보를 보기 전, 태스크별 전역 최적 검사 3개를 고정 선택
Implicit	BED utility 없이 LLM에게 다음 검사를 직접 선택하게 하는 설정

ACTMED는 BED utility를 사용해 환자별로 다음 검사를 선택하며, 각 환자당 최대 3개 검사만 사용.

한계 및 핵심 메시지

한계

- ▶ **데이터 규모:** 전체 약 1,000명
실제 임상 적용 전 대규모 검증 필요
- ▶ **이진 분류만 가능:** 복수 질환·동반 질환 미지원
- ▶ **Feature 수준만:** 모달리티 선택 불가
(영상, 자유 텍스트, 유전체 미지원)
- ▶ **고성능 LLM 의존:** GPT-4o급 필수;
소형 모델 사용 시 프레임워크 전체 실패
- ▶ **계산 비용:** 후보 검사 수와 샘플 수에 비례해
LLM 호출 수 증가

장점

- ▶ 임상 검사 선택을 BED 관점으로 정식화
- ▶ 태스크별 재학습 불필요 (제로샷)
- ▶ 단계별 투명한 추론 과정
- ▶ 임상이가 매 단계 검토·개입 가능
- ▶ 비용 인식적 검사 선택

핵심 메시지

ACTMED는 임상 진단을 **순차적 의사결정 문제**로 재정의.

LLM이 BED의 **서로게이트**로 작동하여, 재학습 없이
환자별 최적 검사를 선택.

현재 LLM은 자율 진단에는 **준비되지 않았지만**, 임상의를
의미있게 **보조**할 수 있음.