


RELATED WORK SURVEY
MULTIMODAL LLM DIAGNOSIS + SEQUENTIAL/ACTIVE MODALITY ACQUISITION

하서준

DGIST

2026년 4월 23일



핵심

LLM을 surrogate simulator로 사용해
BED 기반 순차 검사 선택을 수행
 (Ruhrberg Estévez et al., 2025).

방법


LLM이 후보 검사 결과를 여러 번 가상
 샘플링하고, 각 결과가 진단 확률을
 얼마나 바꾸는지 KL utility로 평가한다.

가져갈 점

별도 policy network 학습 없이, LLM이 가상
 검사 결과를 만들고 utility를 계산해 다음
 검사를 고르는 구조를 가져간다.

HOW CAN IMAGES ENTER AN LLM?

1. Text Summary



이미지를 먼저 **진단 텍스트**로 바꾸고, 그 요약을 LLM의 **prompt input**으로 사용

예시: MoMA

장점

투명성
plug-and-play
추가학습 없음

단점

요약 정보 손실
specialist 품질 의존

2. Visual Token



이미지를 vision encoder/projector가 **LLM embedding input**으로 변환해 직접 reasoning

예시: BLIP-2, Flamingo, LLaVA-Rad, MedTVT-R1

장점


시각 정보 보존
end-to-end reasoning

단점

학습 비용
연결 모듈 설계 필요

방향성: ACTMED의 plug-and-play 장점을 살리고 중간 과정의 투명성을 가져가는 **Text Summary 기반**

2025



핵심


흉부 X-ray를 Medical CLIP 모델과 LLM decoder로 연결해 **진단 텍스트**를 생성하는 medical foundation model (Wang et al., 2025).

방법

CXR → BiomedCLIP-CXR encoder → MLP projector → LLM visual token 으로 연결한다.


가져갈 점

Modality 단위로 CXR를 acquire했을 때, X-ray 이미지를 **진단/finding 텍스트로 변환하는 specialist** 모듈로 사용할 수 있다.



가져갈 점

각 modality를 텍스트로 변환하지 않고, 전용 encoder/projector를 통해 token representation으로 직접 LLM 입력에 주입하는 개념을 참고한다.



핵심

Specialist LLM agent가 CXR/lab을 **텍스트 요약**으로 바꾸고, aggregator/predictor가 이를 통합해 예측 (Gao et al., 2026).

방법



CXR-LLAVA와 Llama-3 specialist가 각 modality를 먼저 자연어 summary로 바꾸고, Llama-3 aggregator/predictor가 이를 통합한다.

가져갈 점

획득한 비텍스트 modality를 **텍스트 요약**으로 바꿔 LLM 상태에 붙이면, 학습 부담을 줄이면서 중간 과정을 사람이 검토할 수 있어 투명성을 확보할 수 있다.

Note: npj Digital Medicine volume/year 기준 2026, DOI suffix는 2025.

TOWARD OUR DIRECTION: ACTMED + MoMA



ACTMED에서 가져갈 것

별도 policy network를 학습하지 않고, LLM을 surrogate로 써서 acquisition loop를 굴리는 추가 학습 없는 적용 가능한 설계.

우리의 방향성

ACTMED + MoMA로 가면 acquisition policy는 추가 학습 없이 유지하면서, 어떤 modality든 텍스트 요약 기반으로 투명하게 modality-level 처리할 수 있다.

MoMA에서 가져갈 것

각 modality를 specialist가 텍스트 요약으로 바꾸고, 요약들을 하나의 LLM 프롬프트로 합쳐 가는 modality-to-text abstraction 구조.

KEY CHALLENGE: MODALITY-LEVEL UTILITY ESTIMATION

ACTMED의 BED 구조를 Modality-level로 올리면
가상 결과 simulation이 불가능해진다.

Feature-level — ACTMED

- ▶ 검사 단위: creatinine, glucose 등 수치
- ▶ LLM이 결과를 직접 샘플링 가능
- ▶ “creatinine이 2.1 나올 것 같다”
- ▶ 그 결과를 더했을 때의 **posterior 확률**을 추정
- ▶ prior와 posterior 사이의 KL utility 계산

Modality-level — Ours

- ▶ 검사 단위: CXR / ECG / Lab panel
- ▶ CXR → 이미지 생성 불가
- ▶ ECG → 파형 생성 불가
- ▶ output space가 달라 동일한 simulation 불성립

Unguided Text Simulation의 신뢰성

현재 환자 정보만 주고 LLM이 미획득 modality 소견을 바로 생성하게 하면, 실제 modality outcome distribution과 달라져 simulation 품질이 크게 떨어질 수 있다.

해결책: RAG-grounded Finding Scenario Generation

- ▶ raw modality 자체가 아니라 finding 텍스트를 생성하되, 유사 환자의 실제 임상 소견을 RAG로 검색해 prompt context로 제공
- ▶ 예: 현재 검사 결과 + ECG 파형이 비슷한 환자를 찾고, 그들의 CXR 소견을 참고
- ▶ LLM이 이를 참고해 “해당 modality를 찍었을 때 나올 법한 finding 텍스트”를 N개 생성
- ▶ 생성된 finding scenario마다 posterior를 추정하고 Expected KL로 utility 계산


유사 환자의 실제 소견으로 grounding해 LLM 생성 결과가 임상적으로 비현실적인 방향으로 벗어나는 것을 억제할 수 있다 (hallucination 억제).

유사 환자 정보에 과도하게 치우치지 않도록 prompt/모델 설계가 필요하며, 실제 성능 향상 여부를 실험으로 검증해야 한다.

OUR PROPOSED MODEL

핵심 아이디어

각 modality를 진단 텍스트로 요약해 aggregator agent가 융합하고, 벡터 DB의 유사 환자를 참고해 가상 결과 텍스트를 생성한 뒤 posterior utility로 다음 modality를 선택한다.



PROMPT COMPARISON: ACTMED vs. OURS

ACTMED: Feature-level Sampling

Prompt 예시 (CKD lab test)

당신은 신장내과 전문의입니다. 현재 환자 정보와 병력을 바탕으로 \$feature_to_sample의 임상적으로 가능한 값을 무작위로 하나 생성하세요. 평균값만 반환하지 말고, plausible range 안에서 전형값, edge case, outlier를 반영하세요.

반환값은 Python float으로 parse 가능한 숫자 하나여야 하며, 단위나 설명은 쓰지 마세요.

Input

Known: age 63, poor appetite,
edema, hypertension, ...
Target feature: serum creatinine

Output

2.7

이 sampling prompt를 $M = 10$ 번 반복하고, 각 sample의 posterior KL을 평균낸다.

ACTMED: uniform mean

$$U(u) = \frac{1}{M} \sum_{j=1}^M KL(B(p_j^{post}) \| B(p^{prior}))$$

분포의 tail에 있는 sample도 평균에서 같은 중요도로 반영될 수 있다.

Ours: Modality-level Scenario Sampling

Prompt 예시 (CXR scenario)

당신은 중환자의학 전문의입니다. 현재 환자 state K_t 와 RAG로 검색된 유사 환자들의 임상 소견을 참고해, 아직 obtain하지 않은 **CXR modality**에서 나올 법한 finding scenario를 생성하세요. 유사 환자 값을 그대로 복사하지 말고, 현재 환자에 맞는 가능한 소견을 생성하세요.

각 scenario는 finding 텍스트와 confidence (0~1)를 포함하세요. confidence는 이 소견이 현재 환자에게 실제로 나타날 가능성을 의미합니다.

Input

Known: age 68, BP 92/58,
Blood lab: WBC 15000, lactate 3.2
Retrieved: similar ECG/lab cases

Output

```
{"finding": "bilateral infiltrates",  
 "confidence": 0.82}
```

이 prompt를 N 번 반복해 scenario set을 만들고, confidence를 scaling한 뒤 posterior KL을 가중합한다.

Ours: adaptive weighting

$$U(m) = \sum_i \tilde{w}_i KL(B(p_i^{post}) \| B(p^{prior}))$$

분포 중심에 가까운 reliable scenario는 confidence를 높이고, 바깥쪽 scenario는 낮게 반영한다.

REFERENCES

-  Gao, J., Rahman, M., Caskey, J., et al. (2026). **Moma: A mixture-of-multimodal-agents architecture for enhancing clinical prediction modelling.** *npj Digital Medicine*, 9(46).
-  Ruhrberg Estévez, S., Astorga, N., & van der Schaar, M. (2025). **Timely clinical diagnosis through active test selection.** *NeurIPS*.
-  Wang, S., et al. (2025). **A clinically accessible small multimodal radiology model and evaluation metric for chest x-ray findings.** *Nature Communications*, 16(3108).
-  Zhang, Y., Yuan, K., Lu, H., Yue, Y., Chen, J., & Wu, K. (2025). **Medtv-r1: A multimodal llm empowering medical reasoning and diagnosis.** *arXiv preprint arXiv:2506.18512*.