

MULTI-AGENT + SEQUENTIAL ACQUISITION 연구 서베이

7 PAPERS FOR MEETING DISCUSSION

하서준

DGIST

2026년 5월 8일

Agent collaboration and sequential evidence acquisition

1. Multi-agent

핵심 질문

여러 specialist/agent를 어떻게 배정, 조정, 검증, 종료할 것인가?

Papers

MAM

ConfAgents

MMedAgent-RL

2. Sequential Acquisition

핵심 질문

비용이 있는 modality/test 중 다음에 무엇을 얻고 언제 멈출 것인가?

Papers

CAMA

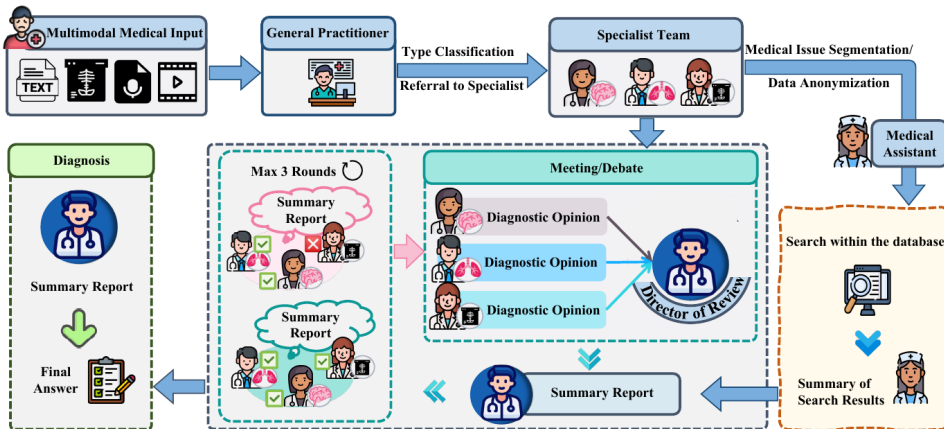
AdaFuse

LDTL

발표 흐름: Multi-agent로 역할/검증 구조를 먼저 잡고, Sequential Acquisition으로 “다음 evidence 선택” 문제로 연결

MAM: MODULAR MULTI-AGENT MEDICAL DIAGNOSIS

Multi-agent · ACL Findings 2025



기존 방법의 문제점

통합 멀티모달 모델은 지식 업데이트 시 전체 재학습이 필요하고, 다양한 임상 태스크에 유연하게 대응할 수 있는 모듈성이 부족하다. 또한 하나의 LLM이 여러 specialty 진단을 모두 잘 수행하기 어렵다.

해결 방법


GP, Specialist, Radiologist, Director로 역할을 분해하고 Medical Assistant가 RAG로 외부 지식을 검색·요약하여 agent 간 토론에 제공한다. 이를 통해 전체 재학습 없이 멀티모달 진단을 수행한다.

Novelty

Role assignment만으로 진단 성능 향상 확인.
GP → Specialist → Director 구조로 재학습 없는 지식 업데이트와 RAG 기반 외부 지식 통합

CONFAGENTS: CONFORMAL-GUIDED ADAPTIVE COLLABORATION

Multi-agent · arXiv 2025



기존 방법의 문제점

기존 방법은 모든 케이스에 동일한 비싼 멀티 에이전트 과정을 적용해 최대 50배 느리다. 또한 LLM이 스스로 보고하는 확신도는 보정이 잘 되어 있지 않아 난이도 구분 어렵고, 정적인 사전학습 지식만으로 새로운 임상 케이스에 대응하기 어렵다.

해결 방법

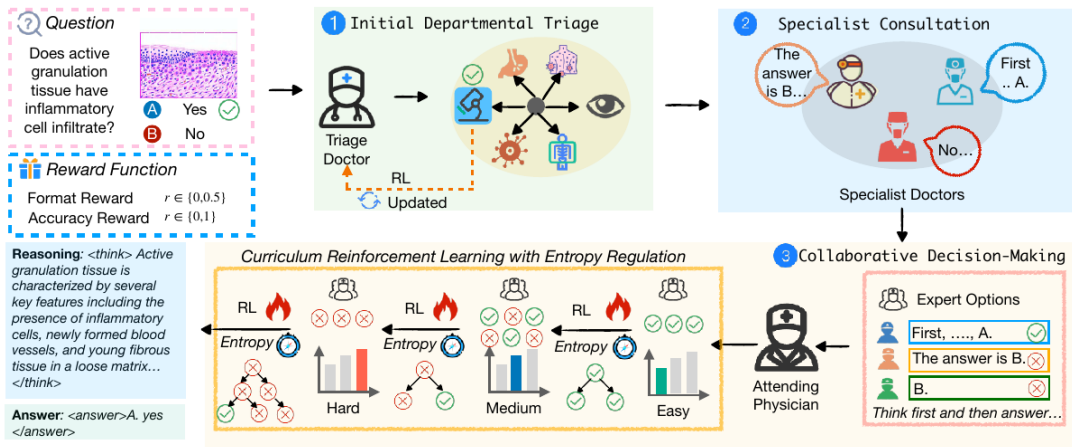
MainAgent가 선택지별 확률을 부여하면, CP Judge가 유사 문제들의 calibration 분포로 불확실한 선택지를 소거한다. 하나만 남으면 즉시 답변하고, 둘 이상 남으면 선택지별 AssistAgent가 의학 문헌을 iterative RAG로 검색해 근거를 수집한다. 마지막으로 MainAgent가 근거를 종합한다.

Novelty

Conformal prediction으로 LLM 확신도 보정 문제 해결. 어려운 케이스에만 협업을 투입해 accuracy 유지 + 최대 7.71배 효율

MMedAGENT-RL: RL-OPTIMIZED MULTI-AGENT COLLABORATION

Multi-agent · ICLR 2026



기존 방법의 문제점

Single Med-LVLM은 다양한 의료 전문 영역을 하나의 모델이 모두 처리해야 해 전문성 일반화에 한계가 있고, 기존 multi-agent는 고정 workflow에 의존해 specialist 의견을 선택적으로 신뢰·수정하는 협업 전략을 학습하지 못한다.

해결 방법




환자를 적절한 진료과로 배정하는 triage agent를 RL로 학습시키고, 각 진료과별 specialist LLM이 진단 의견을 생성하도록 한다. 이후 쉬운 케이스부터 어려운 케이스 순으로 attending physician을 점진적으로 학습시켜, 일부 specialist 의견이 틀리거나 충돌해도 올바른 최종 진단을 내리도록 한다.

Novelty

정적인 multi-agent workflow를 강화학습으로 최적화해 specialist 오류를 극복하는 **dynamic collaboration** 실현

CAMA: COHORT-BASED ACTIVE MODALITY ACQUISITION

Sequential Acquisition · arXiv 2025



기존 방법의 문제점

기존 AFA/AMA는 환자 단위 acquisition에 집중한다. 실제 임상은 코호트 전체 예산이 주어지고, 어떤 환자에게 추가 검사를 줄지 cohort-level로 결정해야 하나 정식화가 부족했다.

해결 방법


Generative imputation으로 missing modality를 시뮬레이션하여, 획득 시 기대 성능 향상이 가장 큰 환자를 우선순위화하는 코호트 단위 acquisition을 수행한다.

Novelty

Cohort-level active modality acquisition 문제를 최초로 정식화

ADAFUSE: ADAPTIVE MULTIMODAL FUSION VIA REINFORCEMENT LEARNING

Sequential Acquisition · arXiv 2026



기존 방법의 문제점

기존 multimodal fusion은 모든 환자에게 동일한 modality를 사용하지만, 특정 환자에게 불필요한 modality는 예측에 도움이 되지 않거나 오히려 노이즈로 작용할 수 있다.

해결 방법


각 환자마다 어떤 modality 조합이 유용한지 RL로 학습하여, 불필요한 modality를 제외하고 informative한 조합만 선택적으로 fusion

Novelty

Patient-specific modality selection을 RL 기반 sequential decision으로 정식화해 noisy modality를 빼고 예측

LDTL: LATENT DIAGNOSTIC TRAJECTORY LEARNING

Sequential Acquisition · arXiv 2026



기존 방법의 문제점

대부분의 LLM 진단 시스템은 full-information setting을 가정한다. Sequential test selection 연구도 reward 중심이라 diagnostic trajectory 분포를 명시적으로 모델링하지 못하고, desirable path supervision도 부족하다.

해결 방법

Planning LLM과 Diagnostic LLM을 분리한다. Diagnostic agent가 test sequence를 latent path로 보고, information gain이 큰 trajectory에 높은 posterior를 부여해 Planning agent가 이를 따르도록 학습한다.

Novelty

Diagnostic trajectory를 latent variable로 모델링. 정답 경로 label 없이 information gain 기반으로 더 적은 검사와 높은 정확도 유도

OUR FRAMING: FROM ACQUISITION TO REASONING

1. 모듈성 부족

기존 modality acquisition은 특정 모델/태스크에 묶여 있어 새로운 modality나 지식 업데이트에 유연하게 대응하기 어렵다.

2. 중간 과정 불투명

RL 기반 선택 정책은 중간 추론 과정을 드러내지 않아, 의사가 판단을 검토하고 개입하는 협업 구조로 확장하기 어렵다.

3. 대부분의 연구가 feature + text 수준에 머무름

기존 연구는 feature를 “획득할지 말지”의 선택 문제로 다루지만, 실제 임상에서 이미지, 파형처럼 비용과 검사 시간이 모두 다른 정보를 어떻게 선택할지는 충분히 다루지 않는다.

현재 진행상황

5/12 MEETING

하서준

DGIST

2026년 5월 12일

CANDIDATE DATASETS FOR ACTIVE MODALITY ACQUISITION

MMIST-ccRCC

설명

멀티모달 의료 데이터셋

CVPR 사용

모달리티

CT

MRI

병리 슬라이드 이미지

Genomics

Clinical data

후보 이유

서로 다른 비용과 결측률을 가진 다양한 의료 모달리티를 함께 검증할 수 있는 데이터셋

MIMIC-CDM

설명

Clinical decision making을 위한 실제 환자 기록 기반 데이터셋

모달리티

Physical: 신체진찰 노트


Lab: 검사 수치 + reference range + microbiology

Imaging: radiology report

후보 이유

표 형태 검사 수치와 임상 텍스트를 이용해, 진단 과정에서 어떤 정보를 다음에 볼지 평가할 수 있는 두 번째 데이터셋

WHY GREEDY SELECTION CAN FAIL



핵심

Greedy는 매 순간 가장 큰 즉시 gain을 고르기 때문에, 단독으로는 약하지만 함께 볼 때 강한 모달리티 조합을 놓칠 수 있다.

HOW CAN WE SEARCH ALL PATHS?

문제: path 수의 폭발

모달리티가 늘어나면 sequential path는 빠르게 증가한다.

예시: Lab, ECG, CXR

Lab → ECG → CXR

Lab → CXR → ECG

ECG → Lab → CXR

ECG → CXR → Lab

CXR → Lab → ECG

CXR → ECG → Lab

순서를 모두 구분하면 permutation space가 되어 탐색 비용이 커진다.

순열 vs 조합

모달리티 수 $n = 5$, 동적으로 멈추는 경우

선택 수 k	순열 $P(5, k)$	조합 $C(5, k)$
1	5	5
2	20	10
3	60	10
4	120	5
5	120	1
합계	325	31

순서를 모두 보면 325개 path를 봐야 하지만, state를 subset으로 보면 31개만 보면 된다.

약 10.5배 감소

핵심

현재 환자 state가 같다면 ABC와 ACB는 같은 정보 집합을 가진다. 따라서 탐색 대상은 순열이 아니라 조합으로 줄어든다.

SSL FOR NEXT-MODALITY SIMULATION

Main idea

그럼 posterior를 어떻게 정확하게 계산해낼 것인가?

아이디어: masking 기반 생성 모듈

모달리티가 모두 있는 환자에서 일부 모달리티를 의도적으로 가림

예시: {Lab, Note, CXR} → CXR mask

예시: {CT, 병리, Genomics, Clinical data} → Genomics mask

남아 있는 모달리티로 가려진 모달리티의 representation을 생성하도록
SSL 학습

Posterior simulation

현재 관측된 정보 O_t 에서 아직 없는 후보 모달리티를 하나씩 생성

$q(e_{\text{Lab}} \mid O_t), q(e_{\text{CXR}} \mid O_t), q(e_{\text{Note}} \mid O_t)$

생성된 representation을 넣었을 때 diagnosis posterior 변화량을 계산

문제: 전체 path를 어떻게 효과적으로 볼 것인가

관측 모달리티 → 생성 모듈 → 후보 모달리티 representation 생성 → posterior 변화 계산 → 다음에 얻을 모달리티 선택