

AdaFuse: Adaptive Multimodal Fusion for Lung Cancer Risk Prediction via Reinforcement Learning


환자별 modality selection을 통한 medical multimodal fusion

Chongyu Qu et al.

MIDL 2026 Full Paper

2026년 5월 14일

Motivation: Why Adaptive Fusion?



기존 multimodal learning은 주로 주어진 modality들을 어떻게 fusion할지에 집중했다.

핵심 질문

예측에 꼭 모든 modality를 써야 할까?

Dataset & Feature Inputs

Dataset

NLST lung cancer risk prediction | Train 1,847 / Test 462 | Positive rate $\approx 6\%$

A. CT image

Sybil pretrained
encoder

$$\mathbf{f}_A \in \mathbb{R}^{512}$$

B. Clinical variables

PLCOm2012 risk factors

$$\mathbf{f}_B \in \mathbb{R}^{17}$$

C. Text report

Synthetic report + CORE
embedding

$$\mathbf{f}_C \in \mathbb{R}^{768}$$

$$\mathbf{f}_A$$

CT encoder

$$\mathbf{h}_A \in \mathbb{R}^{32}$$

$$\mathbf{f}_B$$

Clinical encoder

$$\mathbf{h}_B \in \mathbb{R}^{32}$$


$$\mathbf{f}_C$$

Text encoder

$$\mathbf{h}_C \in \mathbb{R}^{32}$$

각 modality는 별도 encoder path를 거쳐 공통 32D representation으로 projection

Overall AdaFuse Framework



State Encoder and Policy Head

Policy network는 현재까지 선택된 modality state를 보고 다음 action의 확률분포를 출력한다.

1. State Encoder

$$s_t = g_{\theta}([h_A \odot m_A; h_B \odot m_B; h_C \odot m_C; \mathbf{m}])$$

- ▶ h_A, h_B, h_C : 32D encoded modality features
- ▶ $\mathbf{m} \in \{0, 1\}^3$: selected modality mask
- ▶ unselected modality는 zero-out
- ▶ output: $s_t \in \mathbb{R}^{64}$

선택된 modality와 feature 정보를 64D state vector로 요약

2. Policy Head

$$\pi_{\theta}(a_t | s_t) = \text{softmax}(l_t / \tau)$$

- ▶ 64D state vector s_t 를 입력으로 받음
- ▶ step-specific head가 action logits l_t 출력
- ▶ Training: temperature 기반 sampling
- ▶ Inference: greedy decoding

다음 action에 대한 확률분포 생성

Fusion Methods

$$h_A, h_B, h_C \in \mathbb{R}^{32}$$

Concat

$$[h_A; h_B; h_C]$$

선택된 modality feature를
그대로 concatenate

Triple: $32 \times 3 = 96D$

Mean

$$(h_A + h_B + h_C)/3$$

공통 32D representation을
element-wise average

Triple output은 32D

Tensor

$$[h_A; 1] \otimes [h_B; 1] \otimes [h_C; 1]$$

modality 간 multiplicative
interaction을 명시적으로 생성

Naive 32D 기준:

triple $(32 + 1)^3$

Fusion step

환자마다 어떤 modality 조합을 쓰느냐에 따라 최적 fusion 방식도 달라질 수 있다는 가정

Reward Design

$$r = r_{\text{BCE}} + \lambda_{\text{AUC}} \cdot r_{\text{AUC}} \quad r_{\text{BCE}} = y \log \hat{p} + (1 - y) \log(1 - \hat{p})$$

BCE reward

- ▶ Negative BCE 형태
- ▶ 개별 환자 예측이 정답에 가까울수록 reward 증가

AUC reward

- ▶ mini-batch 내 positive/negative 쌍별 비교
- ▶ 암 환자 score가 정상인 score보다 반드시 높아야 reward를 받음
- ▶ → 모델이 암 환자를 정상인과 명확히 구분하도록 강제

목적

좋은 예측과 좋은 ranking을 만든 modality/fusion 선택 경로에 더 높은 reward를 부여

Policy Gradient Optimization

좋은 선택은 강화하고, 탐색은 유지하며, 예측은 안정화한다.

$$L = L_{PG} - \lambda_{ent} \sum_t H(\pi_{\theta}(\cdot | s_t)) + \lambda_{sup} L_{BCE}$$

$H(\pi_{\theta}(\cdot | s_t))$: entropy

1. Policy gradient loss

Reward가 높은 modality/fusion trajectory의 선택 확률을 높임

2. Entropy regularization

Policy가 초기에 한 action으로 collapse되는 것을 방지

3. Supervised BCE loss

예측 결과가 정답 label에 가까워지도록 안정화

Policy gradient term

$$\tau_{traj} = (a_1, a_2, \dots) \Rightarrow \log \pi_{\theta}(\tau_{traj}) = \sum_t \log \pi_{\theta}(a_t | s_t) \Rightarrow L_{PG} = - \log \pi_{\theta}(\tau_{traj})(r - \bar{r})$$

$\bar{r}$: mini-batch 평균 reward

Main Results

Method	AUC	MFLOPs
<i>A</i> (CT)	0.732	0.543
<i>B</i> (Clinical)	0.662	0.017
<i>C</i> (Text)	0.576	1.067
<i>AB</i> -concat	0.758	0.559
<i>AB</i> -mean	0.755	0.557
<i>AB</i> -tensor	0.735	0.433
<i>AC</i> -concat	0.733	1.610
<i>AC</i> -mean	0.745	1.608
<i>AC</i> -tensor	0.739	1.477
<i>BC</i> -concat	0.661	1.084
<i>BC</i> -mean	0.678	1.082
<i>BC</i> -tensor	0.685	1.088
<i>ABC</i> -concat	0.735	1.626
<i>ABC</i> -mean	0.748	1.622
<i>ABC</i> -tensor	0.759	1.790
MoE	0.742	3.492
DynMM	0.754	1.635
AdaFuse (Ours)	0.762	1.164

Key observations

1. Best AUC, 하지만 margin은 작음
AdaFuse 0.762 vs ABC-tensor 0.759


2. More modalities $\neq$ better performance
AB-concat 0.758 > ABC-concat 0.735

3. 더 나은 AUC-cost trade-off
AdaFuse 1.164 MFLOPs
DynMM 1.635, MoE 3.492

MFLOPs

모델이 한 번 예측할 때 필요한 부동소수점 연산 수를 백만 단위로 나타낸 계산 비용 지표

Training Configuration Ablation



Encoder	Classifier	Test AUC	Δ
Train	Freeze	0.762	—
Freeze	Train	0.722	-5.25%
Train	Train	0.691	-9.32%
Freeze	Freeze	0.674	-11.55%

핵심 해석

1. Classifier는 freeze하는 것이 가장 좋음

Train encoder + Freeze classifier = 0.762

2. Classifier까지 학습하면 reward signal이 불안정해질 수 있음

선택된 classifier만 gradient를 자주 받아, 덜 선택된 classifier는 undertrained될 수 있음.

Learning Objective Ablation

	Configuration	Test AUC	Δ
Best	$\mathcal{L}_{PG} + 0.1\mathcal{H} + 0.3\mathcal{L}_{sup}, \quad r = 0.7r_{BCE} + 0.3r_{AUC}$	0.762	—
Same Reward	$\mathcal{L}_{PG} + 0.1\mathcal{H}$ (no supervision)	0.696	-8.7%
	$\mathcal{L}_{PG} + 0.3\mathcal{L}_{sup}$ (no entropy)	0.610	-20.0%
	$\mathcal{L}_{PG}$ (policy gradient only)	0.689	-9.6%
	$\mathcal{L}_{PG} + 1.0\mathcal{L}_{sup}$ (over-weighted supervision)	0.641	-15.9%
Same Loss	$r = r_{AUC}$ (AUC reward only)	0.647	-15.1%
	$r = r_{BCE}$ (BCE reward only)	0.637	-16.4%

1. Same Reward

- ▶ Entropy 제거가 가장 치명적
→ 15개 조합 탐색에서 초기 다양성이 결정적
- ▶ Supervision이 너무 강하면 selection 학습이 약해짐
→ reward signal을 압도하면 policy가 selection 자체를 못 배움

2. Same Loss

- ▶ BCE/AUC 단독 reward는 모두 성능 하락
- ▶ positive rate 6% 환경에서
BCE만으로는 ranking signal이 부족하고,
AUC만으로는 gradient가 sparse함
→ 두 reward가 상호보완적

Uncertainty-Guided Latent Diagnostic Trajectory Learning for Sequential Clinical Diagnosis

Sequential evidence acquisition for clinical diagnosis

Xuyang Shen, Haoran Liu, Dongjin Song, Martin Renqiang Min

arXiv 2026

Problem: 기존 LLM Diagnosis의 한계

1. Full-information assumption

모든 정보를 미리 준다고 가정.

→ 실제 임상과 괴리

2. No path supervision

Sequential하게 다루더라도 어떤 검사 순서가 좋은지 label이 없음.

→ good path를 supervised 학습할 수 없음

3. Reward-only optimization


Terminal reward만으로는 중간 경로의 질을 직접 평가하기 어려움.

→ path 구조 제어와 학습 안정성이 약함

핵심 질문

정답 경로 label 없이 어떻게 좋은 diagnostic trajectory를 정의하고 학습할 것인가?

Overall Framework: Planning Agent + Diagnostic Agent



Planning LLM agent

현재 상태 h_t 에서 다음 검사 action a_t 를 선택한다.

$$h_t \rightarrow a_t \rightarrow h_{t+1} \rightarrow \hat{y}, \text{ confidence, stop}$$

Diagnostic LLM agent

업데이트된 상태 h_{t+1} 에서 disease prediction, confidence, stop 여부를 낸다.

Problem Formulation

Notation

- ▶ 초기 상태: h_0
- ▶ Action: $a_t \in \mathcal{A}$
- ▶ Action space: $\{\text{lab, physical, image}\}$
- ▶ 상태 업데이트: $h_{t+1} = \text{Update}(h_t, a_t)$

Trajectory

$$z = (a_1, \dots, a_T)$$

z 는 미리 주어진 label이 아니라 step-by-step 선택이 누적되어 만들어지는 검사 경로다.

핵심 메시지

목표는 accurate diagnosis와 fewer tests 사이의 균형

Why “Latent” Trajectory?

데이터에서 관측되는 것

- ▶ 초기 patient state h_0
- ▶ 사용 가능한 test results: lab / physical / image
- ▶ 최종 disease label y

데이터에서 관측되지 않는 것

- ▶ Optimal diagnostic trajectory z^*
- ▶ 어떤 test를 먼저 획득해야 하는가?
- ▶ 언제 diagnosis를 종료해야 하는가?

핵심 메시지

“Latent”는 patient information이 숨겨져 있다는 뜻이 아니다.
좋은 diagnostic path에 대한 label이 관측되지 않는다는 뜻이다.

What Makes a Good Diagnostic Path?

동기

- ▶ 문제: 정답 label y 는 있지만 optimal trajectory z^* 는 없다.
- ▶ 목표: “정답 진단에 더 기여하는 경로”를 높은 preference로 표현한다.

Trajectory-level

$$q(z \mid h_0, y) = \frac{\exp(\beta S(z))}{\sum_{z' \in Z(h_0)} \exp(\beta S(z'))}$$

- ▶ $S(z)$: trajectory z 가 정답 y 를 얼마나 잘 지지하는가
- ▶ β : 분포의 sharpness 조절

Action-level

$$q(a_t \mid h_t, y) = \sum_{z: z_t = a_t} q(z \mid h_0, y)$$

Full $q(z \mid h_0, y)$ 가 있다면, t 번째 action이 a_t 인 trajectory posterior를 합산해 action-level teacher를 만들 수 있다.

한계

Trajectory space가 지수적으로 커지므로 모든 z 에 대해 $S(z)$ 를 평가하고 $q(z \mid h_0, y)$ 를 직접 계산하기 어렵다.

IG Approximation

근사 아이디어 전체 경로 대신 “이 action 하나를 추가하면 정답 확률이 얼마나 오르는가?”로 대체

$$\text{IG}(h_t, a) = \log p_{\psi}(y \mid h_{t+1}) - \log p_{\psi}(y \mid h_t)$$

$$q(a \mid h_t, y) \propto \exp(\text{IG}(h_t, a)/\tau)$$

핵심 메시지

trajectory-level posterior를 one-step information gain으로 근사한다.

Action posterior

$$q(a \mid h_t, y)$$

현재 state에서 각 candidate action의 IG를 계산해 teacher action distribution으로 변환한다.

Train the Planner to Follow the Teacher

동기

- ▶ 목표: planner π_θ 가 teacher q 를 모방하도록 학습

Planner loss

$$L_{\text{planner}} = \sum_{t=1}^T \text{KL}(q(a \mid h_t, y) \parallel \pi_\theta(a \mid h_t))$$

학습 방향

teacher distribution $q(a \mid h_t, y)$ 와 planner policy $\pi_\theta(a \mid h_t)$ 사이의 차이를 줄인다.

Dataset and Action Space

MIMIC-CDM

- ▶ 2,400 inpatient cases
- ▶ 4 abdominal diseases:
 - appendicitis (충수염)
 - cholecystitis (담낭염)
 - diverticulitis (게실염)
 - pancreatitis (췌장염)
- ▶ Split: 70 / 10 / 20
- ▶ Backbone: Llama-3-8B + LoRA

Action space

- ▶ lab
- ▶ physical
- ▶ image

Main Results

Method	Accuracy				F1-Score	
	Appendicitis	Cholecystitis	Diverticulitis	Pancreatitis	Mean	
SFT-all	97.9	93.1	90.4	90.7	94.2	95.8
Fixed info (history) (ZS)	47.9	34.6	73.1	79.6	54.1	58.8
Fixed info (history + one test) (ZS)	50.5	47.7	76.9	72.2	58.3	60.5
Fixed info (history + two tests) (ZS)	60.9	60.7	78.8	80.5	67.2	68.2
All info (ZS)	73.9	70.0	82.7	87.9	76.9	76.7
Planner random selection	82.8	85.4	90.4	85.2	84.8	83.7
ReAct (Yao et al., 2022)	90.2	79.7	66.7	62.9	74.9	79.1
LA-CDM (Bani-Harouni et al., 2025b)	93.1	83.6	75.0	73.5	81.3	84.1
LDTL	98.9	95.4	<u>78.8</u>	87.9	93.4	91.7

결과 구조

Upper bound

SFT-all 94.2 → 모든 정보를 다 봤을 때 성능

Sequential baselines

Random 84.8, ReAct 74.9, LA-CDM 81.3

LDTL

93.4 → SFT-all에 근접, sequential 중 최고

의미

긍정적 해석

Sequential baselines 중 최고 성능이며, SFT-all과 0.8% 차이 → sequential 제약 하에서 거의 upper bound에 도달


비판적 시각

Random planner 84.8이 ReAct보다 높음 → action space가 3개뿐이라 random도 잘 됨 → LDTL 개선이 framework 때문인지 task 난이도 때문인지 불분명

클래스별 패턴

Diverticulitis는 LDTL이 random보다 낮음 → 일부 class에서는 trajectory learning이 오히려 해가 될 수 있음

Case Study: Effect of Latent Path Regularization




- ▶ Patient 1: LDTL은 더 짧은 경로로 correct diagnosis에 도달한다.
- ▶ w/o LP는 추가 imaging 후 lab test까지 요청한다.

Interpretation

Figure 3는 latent path regularization이 informative action을 더 일찍 선택하도록 돕는다는 정성적 예시다.

Ablation + Efficiency

Method	Acc	Macro-F1	App.	Chol.	Div.	Pan.
RS	84.8	83.7	82.8	85.4	90.4	85.2
w/o LP	88.6	88.5	94.8	90.7	80.7	78.7
LDTL	93.4	91.7	98.9	95.4	78.8	87.9



Ablation

- ▶ Random selection: 84.8
- ▶ w/o LP: 88.6
- ▶ LDTL: 93.4
- ▶ State-conditioned planner만으로도 random보다 좋아진다.
- ▶ Trajectory-level posterior alignment가 추가 향상을 만든다고 주장한다.
- ▶ LDTL은 one-step termination이 많고 three-step trajectory가 적다.

Discussion / Concern

Termination이 정말 calibrated confidence로 잘 결정되는지, confidence 학습 방식은 명확하지 않다.

Three Acquisition Objectives with Alternative Branches

