

MIMIC-CDM 기반 Sequential Clinical Diagnosis 연구 동향

Path Supervision과 Stopping 문제를 중심으로


하서준

DGIST

2026년 5월 22일

LA-CDM · LDTL · SIFT · CaRT · MIMIC-CDM

Survey Map



최근에 생긴 문제 세팅

MIMIC-CDM (2024)이 **sequential evidence acquisition**을 benchmark로 만들면서, LLM diagnosis가 “full information classification”에서 “어떤 검사를 언제 볼 것인가”를 학습하는 문제로 이동했다.

오늘의 발표 흐름

1. **LA-CDM**: MIMIC-CDM에서 RL clinical decision making을 어떻게 문제화했는가
2. **LDTL**: path label 부재를 local information gain으로 어떻게 우회했는가
3. **SIFT**: terminal reward 대신 critical evidence reward를 어떻게 만들었는가
4. **Combination 관점**: 검사 조합의 utility를 직접 보면 무엇이 달라지는가
5. **OpenReview**: LA-CDM은 어떤 약점에도 불구하고 왜 accepted 되었는가

발표의 중심 질문

정답 diagnosis label은 있지만 **좋은 diagnostic path label은 없다**. 기존 논문들은 이 빈칸을 어떤 proxy로 메우고 있는가?

Language Agents for Hypothesis-driven Clinical Decision Making with Reinforcement Learning

LA-CDM

ICLR 2026

LA-CDM: 문제 제기

1. 기존 clinical RL은 주로 tabular data만 고려함

기존 reinforcement learning 기반 clinical decision-making은 주로 **tabular data**에 맞춰져 있다. 그래서 clinical notes, imaging reports처럼 실제 진단에서 중요한 modality를 놓친다.


2. 기존 LLM clinical decision-making은 대부분 zero-shot임

기존 LLM 기반 clinical decision-making은 prompting이나 zero-shot reasoning에 의존한다. 즉, **diagnostic test selection**과 **sequential decision-making 자체를 명시적으로 학습하지 않는다**.


LA-CDM의 문제 설정

그래서 LA-CDM은 multimodal patient state에서 test를 순차적으로 요청하고, confidence가 충분할 때 diagnosis를 내리는 LLM-based clinical decision-making 문제를 제시한다.

LA-CDM: Main Figure



LA-CDM: 방법



Cyclic training objectives

1. Hypothesis generation

HA가 각 state에서 정답 diagnosis y_{true} 를 생성하도록 SFT.

2. Uncertainty-awareness

confidence가 $J(h_j) = \mathbb{I}[h_j = y_{\text{true}}]$ 에 맞도록 GRPO calibration.

3. Efficient action selection

DA가 필요한 test와 stop/diagnosis를 GRPO로 학습.

DA phase reward



$$R_{\text{diag}} = \begin{cases} r_{\text{pos}} & y_{\text{pred}} = y_{\text{true}} \\ r_{\text{neg}} & y_{\text{pred}} \neq y_{\text{true}} \\ r_{\text{invalid}} & \text{format error} \end{cases}$$

$$R_{\text{cost}}(T) = - \sum_{t_j \in T} c(t_j)$$

이 reward는 **efficient action selection phase**에서만 쓰인다. Hypothesis SFT와 confidence calibration은 별도 objective로 cycle 안에서 번갈아 학습된다.

LA-CDM: 결과와 의미

Method	Accuracy					F1-Score		Avg. Test Cost
	Append.	Cholec.	Divert.	Pancr.	Mean	Micro	Macro	
OASST*	82.0	48.0	45.5	44.1	54.9	-	-	-
SFT-all	98.4	89.8	95.8	87.5	92.8	93.6	92.9	\$3792.79
SM-DDPO ⁺	74.3	0.0	15.6	58.0	37.0	45.4	31.8	-
ReAct	90.2	79.7	66.7	62.9	74.9	79.1	74.8	\$1480.32
LA-CDM (ZS)	73.5	55.1	72.0	57.5	64.5	65.3	64.5	\$1521.73
LA-CDM	93.1	83.6	75.0	73.5	81.3	84.1	81.3	\$1295.61



결과가 주장하는 것

- ▶ LA-CDM mean accuracy 81.3, macro F1 81.3
- ▶ ReAct보다 높은 성능과 낮은 평균 test cost
- ▶ training 후 confidence calibration도 개선

Uncertainty-Guided Latent Diagnostic Trajectory Learning for Sequential Clinical Diagnosis

LDTL

arXiv 2026

LDTL: 문제 제기

1. LLM 진단은 test selection을 명시적으로 모델링하지 못함

LLM 기반 diagnostic system은 진단을 생성할 수는 있지만, 실제 임상 경로처럼 어떤 test를 어떤 순서로 선택해야 하는지를 명시적으로 모델링하지 못한다.


2. Terminal reward만으로는 trajectory 학습이 부족함

terminal reward로 성능과 비용을 최적화하는 방식은 **diagnostic trajectory의 구조나 분포**를 직접 제어하지 못한다. 따라서 제한된 clinical trajectories에서 불안정하고, 어떤 path가 바람직한지에 대한 supervision이 약하다.

LDTL의 문제 설정

그래서 LDTL은 test selection을 **Latent Diagnostic Trajectory Learning** 문제로 두고, 단순 reward가 아니라 diagnostic improvement 기반의 action signal을 만들려고 한다.

LDTL: Main Figure



LDTL: ideal vs. approximation

Ideal: trajectory posterior

$$q(z \mid h_0, y) = \frac{\exp(\beta S(z))}{\sum_{z' \in Z(h_0)} \exp(\beta S(z'))}$$

$$q(a_t \mid h_t, y) = \sum_{z: Z_t = a_t} q(z \mid h_0, y)$$

trajectory z	$S(z)$	$q(z)$
(A, B, C)	3.0	0.30
(A, C, B)	2.0	0.12
(B, A, C)	2.5	0.20
(B, C, A)	3.5	0.35
(C, A, B)	1.0	0.02
(C, B, A)	0.5	0.01

$$q(A) = 0.42, \quad q(B) = 0.55, \quad q(C) = 0.03$$

B 단독 gain이 작아도, B 로 시작하는 좋은 future trajectory가 많으면 B 가 선택된다.

Approx.: one-step IG

$$IG(h_0, a) = \log p(y \mid h_0 + a) - \log p(y \mid h_0)$$

$$q(a \mid h_0, y) \propto \exp(IG(h_0, a)/\tau)$$

action	one-step IG
A	0.70
B	0.50
C	0.10

$$IG(A) > IG(B) > IG(C)$$

실제 근사는 A 를 더 선호한다. 하지만 $B \rightarrow C \rightarrow A$ 처럼 최종 utility가 큰 조합은 명시적으로 평가하지 않는다.

LDTL: approximation gap

Trajectory marginal을 전개하면

현재 action 이후의 future trajectory를 τ 라고 두면 $z = (a, \tau)$ 이다.

$$q(a \mid h_t, y) \propto \sum_{\tau} \exp(\beta S(a, \tau))$$

만약 trajectory score가 immediate gain과 future utility로 나뉜다면

$$\begin{aligned} S(a, \tau) &= IG(h_t, a) + S_{\text{future}}(\tau \mid h_t, a) \\ q(a \mid h_t, y) &\propto \exp(\beta IG(h_t, a)) \underbrace{\sum_{\tau} \exp(\beta S_{\text{future}}(\tau \mid h_t, a))}_{Z_{\text{future}}(h_t, a)} \end{aligned}$$

LDTL approximation이 생략하는 항

LDTL의 one-step IG posterior는 $Z_{\text{future}}(h_t, a)$ 를 계산하지 않는다. 이 근사가 맞으려면 $Z_{\text{future}}(h_t, a)$ 가 action마다 거의 같아야 한다.

LDTL: 방법

Stage 1. Diagnostic LLM을 먼저 학습

full patient information, 즉 complete diagnostic results가 주어졌을 때 correct disease label을 예측하고 confidence score를 출력하도록 diagnostic LLM을 SFT한다.

Stage 2. Diagnostic LLM은 freeze하고 planner를 학습

학습된 diagnostic LLM을 고정한 뒤, planning LLM이 어떤 diagnostic action을 선택할지 학습한다. 각 step에서 action을 넣어본 뒤 **diagnostic improvement**로 action-level posterior $q(a_t | h_t, y)$ 를 만들고, planner policy를 여기에 맞춘다.

$$\mathcal{L}_{\text{planner}} = \sum_{t=1}^T \text{KL}(q(a | h_t, y) \| \pi_{\theta}(a | h_t))$$

핵심

정답 trajectory를 직접 만들지 않고, **freeze된 diagnostic LLM의 probability 변화**를 이용해서 planner supervision을 만든다.

LDTL: 결과와 의미

Method	Acc	Macro-F1	App.	Chol.	Div.	Pan.
RS	84.8	83.7	82.8	85.4	90.4	85.2
w/o LP	88.6	88.5	94.8	90.7	80.7	78.7
LDTL	93.4	91.7	98.9	95.4	78.8	87.9




Figure 4: Distribution of diagnostic termination steps

Learning What Matters: Criticality-Guided Reinforcement Learning for Sequential Clinical Diagnosis

SIFT

Preprint 2026

SIFT: 문제 제기

1. 기존 benchmark는 action과 diagnosis를 닫힌 공간으로 제한함

AMIE, ED-Copilot, LA-CDM 계열은 action space를 predefined test menu로 제한하고, diagnosis space도 fixed label set으로 둔다. 반면 실제 clinical reasoning은 open-ended interaction에 가깝다.



2. Terminal reward는 evidence quality를 보지 못함

최종 diagnosis가 맞았는지는 알려주지만, trajectory가 모은 evidence가 좋은지는 말해주지 않는다. 그래서 policy가 critical finding과 noise를 구분하지 못하고 **indiscriminate information acquisition**으로 흐를 수 있다.

SIFT의 문제 설정

정답 path를 직접 만들기보다, trajectory가 **critical evidence**를 얼마나 회수했는지를 reward signal로 만든다.

SIFT: Main Figure



SIFT: 사전 criticality scoring

EXAMPLE (illustrative only)

ACTION_HISTORY:

```
[
  {
    "action": "Order comprehensive metabolic panel",
    "result": "Lipase returned at 1200 U/L. ALT is 85 U/L."
  },
  {
    "action": "Ask about alcohol use",
    "result": "Patient denies alcohol use."
  }
]
```

FACT_LIST:

```
[
  "Lipase 1,200 U/L",
  "ALT 85 U/L",
  "AST 72 U/L",
  "No alcohol use"
]
```

Output:

discovered_fact_indices: [0,1,3]

1. Fact extraction

Training 전에 patient record M 에서 atomic clinical facts를 추출한다.

$$F = \phi(M) = \{f_1, \dots, f_n\}$$

각 f_i 는 lab value, imaging finding, physical exam result처럼 해석이 섞이지 않은 단일 observation이다.

2. Criticality scoring

$$w_f = \psi(f | d^*, o_0), \quad w_f \in \{0, 1, 2, 3\}$$

gold diagnosis d^* 와 initial presentation o_0 기준으로 각 fact가 얼마나 diagnosis를 confirm하는지 점수화한다.

Score meaning

- ▶ 0: diagnosis와 무관
- ▶ 1: supportive but non-specific evidence
- ▶ 2: significant evidence
- ▶ 3: hallmark / pathognomonic finding

Scoring은 offline으로 수행되어 rollout 중 ψ 를 호출하지 않는다.

SIFT: 방법

1. 왜 terminal reward만으로 부족한가

최종 diagnosis가 맞았는지만 보는 binary reward는 episode 끝에서만 관측된다. 어떤 action이 correct diagnosis에 기여했는지 알려주지 못하고, agent가 진단적으로 무관한 정보까지 넓게 수집하는 방향으로 흐를 수 있다.

2. Critical recall

Trajectory가 회수한 critical facts의 비율을 측정한다.

$$CR(\tau) = \frac{\sum_{f \in D(\tau)} w_f}{\sum_{f \in F} w_f}$$

F : 전체 fact set, $D(\tau)$: 발견된 fact set, w_f : criticality score.

3. Criticality-weighted reward

정답 여부와 critical evidence 회수를 같이 reward에 반영한다.

$$R(\tau) = (\alpha CR(\tau) + \beta) \text{acc}(\hat{d}, d^*) + \eta CR(\tau) - \lambda \frac{t}{T}$$

같은 diagnosis accuracy라도 critical evidence를 더 많이 회수하면 reward가 커진다. 마지막 항은 step penalty다.

SIFT: 결과와 의미




Figure 2: Diagnostic accuracy versus evidence acquisition behavior for different policies. Each point represents a model or policy: the base model is the untrained Qwen3-32B, SIFT ($\eta=0$) and SIFT ($\eta=0.2$) are criticality-weighted reward variants, and Info Recall rewards the fraction of all facts discovered regardless of criticality.

Table 2: logistic regression that tests whether evidence quality (critical information, noise, and coverage) predicts diagnostic success, while controlling for differences between models and accounting for repeated evaluations on the same cases ($N = 324$).

Predictor	Coefficient	Std. Error	p-value
Critical info ratio	9.155	2.077	< 0.001
Noise ratio	-1.706	1.058	0.107
Info coverage	1.479	0.838	0.077
Model fixed effects		Included	

결과 해석: evidence의 양보다 critical evidence ratio가 diagnostic success를 가장 강하게 설명한다.

왜 trajectory를 모델링해야 할까? = 왜 greedy가 실패하나?

핵심 문제

좋은 diagnostic path에는 정답 label이 없다. 그래서 기존 연구들은 terminal reward, local information gain, critical fact recall 같은 proxy를 만든다.

Greedy가 아는 것

현재 state S 에서 action a 하나를 추가했을 때의 즉시 변화만 본다.

$$\Delta U(a | S) = U(S \cup \{a\}) - U(S)$$

이 값이 크면 지금 당장은 좋아 보인다.

Greedy가 모르는 것

그 action이 이후 어떤 검사 조합을 열어주는지, 혹은 이미 얻은 정보와 얼마나 겹치는지는 보지 못한다.

$$U(S \cup A \cup B) \neq U(S \cup A) + U(S \cup B)$$


synergy와 redundancy는 trajectory 전체에서 드러난다.

정리

“중간 reward가 없어서 어렵다”는 반만 맞는 설명이다. 더 근본적인 문제는 **중간 reward를 무엇으로 정의해야 trajectory-level utility를 보존하는가**다.


Greedy가 실패하는 예시: combination effect

Example 1: same second test C



Greedy는 $U(A) > U(B)$ 라서 A 를 고른다. 하지만 같은 C 를 붙이면 $B + C$ 가 더 높다.

Example 2: different second test



처음엔 A 가 더 좋아 보이지만, B 가 D 와 만나면 더 큰 trajectory utility를 만든다.

의미

이 현상은 검사 정보가 독립적이지 않다는 뜻이다. 한 검사의 가치는 단독 값이 아니라 **이후 어떤 검사와 결합되는지**에 따라 달라진다.