

MIMIC-CDM 기반 Sequential Clinical Diagnosis 연구 동향

Path Supervision과 Stopping 문제를 중심으로


하서준

DGIST

2026년 5월 22일

LA-CDM · LDTL · SIFT · CaRT · MIMIC-CDM

Survey Map



최근에 생긴 문제 세팅

MIMIC-CDM (2024)이 **sequential evidence acquisition**을 benchmark로 만들면서, LLM diagnosis가 “full information classification”에서 “어떤 검사를 언제 볼 것인가”를 학습하는 문제로 이동했다.

오늘의 중점 주제

좋은 trajectory가 무엇인가?

정답 diagnosis label은 있지만 **좋은 diagnostic path label은 없다**. 그래서 최근 연구들은 좋은 trajectory를 직접 관측하지 못한 상태에서, 각자 다른 proxy로 이 빈칸을 메우고 있다.

- ▶ **LA-CDM**: 정확도와 검사 비용을 최적화하는 RL
- ▶ **LDTL**: 전체 trajectory를 우리가 모르는 latent로 두고, one-step information gain으로 근사
- ▶ **SIFT**: 중간 검사에 보상을 주어 좋은 검사를 많이 회수했는지 강화학습

MIMIC-CDM 데이터셋

Benchmark 목적

환자에게 모든 정보가 한 번에 주어지는 classification 문제가 아니라, **검사를 순차적으로 선택**하면서 diagnosis를 맞히는 clinical decision-making benchmark를 만든다.

규모와 label

총 **2,400명**의 abdominal disease 환자 사례.

Disease list

- ▶ appendicitis (충수염)
- ▶ cholecystitis (담낭염)
- ▶ diverticulitis (게실염)
- ▶ pancreatitis (췌장염)

Action space: 12 actions

- 1. Lab tests** 7 actions
Complete Blood Count, Basic Metabolic Panel, Comprehensive Metabolic Panel, Renal Function Panel, Liver Function Panel, Urinalysis, Electrolyte Panel
- 2. Imaging reports** 4 actions
CT, MRI, Radiograph, Ultrasound
- 3. Physical examination** 1 action

일부 환자에서는 특정 검사 결과가 기록되지 않은 경우가 있다.

Language Agents for Hypothesis-driven Clinical Decision Making with Reinforcement Learning

LA-CDM

ICLR 2026

LA-CDM: 문제 제기

1. 기존 clinical RL은 주로 tabular data만 고려함

기존 reinforcement learning 기반 clinical decision-making은 주로 **tabular data**에 맞춰져 있다. 그래서 clinical notes, imaging reports처럼 실제 진단에서 중요한 modality를 놓친다.


2. 기존 LLM clinical decision-making은 대부분 zero-shot임

기존 LLM 기반 clinical decision-making은 prompting이나 zero-shot reasoning에 의존한다. 즉, **diagnostic test selection**과 **sequential decision-making 자체를 명시적으로 학습**하지 않는다.

LA-CDM의 문제 설정

그래서 LA-CDM은 multimodal patient state에서 test를 순차적으로 요청하고, confidence가 충분할 때 diagnosis를 내리는 LLM-based clinical decision-making 문제를 제시한다.

LA-CDM: Main Figure




구성요소

Hypothesis: 현재까지 얻은 patient state를 바탕으로 가능한 diagnosis 후보를 유지한다.

Decision agent: 다음 test를 요청하거나, 충분한 confidence가 있으면 최종 diagnosis를 선택한다.

LA-CDM: 방법



Cyclic training objectives

DA GRPO

HA가 낸 hypothesis와 confidence를 보고, 다음 test를 볼지 diagnosis를 낼지 학습한다.

HA SFT

현재까지 관측된 patient state에서 정답 diagnosis hypothesis를 생성하도록 학습한다.

HA confidence GRPO

맞는 hypothesis는 높은 confidence, 틀린 hypothesis는 낮은 confidence를 내도록 보상한다.

DA GRPO → HA SFT → HA confidence GRPO를 반복한다.

DA phase reward

$$R_{DA} = R_{diag} + R_{format} + R_{cost}$$



$$R_{diag} = \begin{cases} r_{pos} & y_{pred} = y_{true} \\ r_{neg} & y_{pred} \neq y_{true} \end{cases}$$

$$R_{cost}(T) = - \sum_{t_j \in T} c(t_j)$$

- ▶ R_{format} : output format 위반 penalty.
- ▶ 이 reward는 DA action-selection phase에 사용.

LA-CDM: 결과와 의미

Method	Accuracy					F1-Score		Avg. Test Cost
	Append.	Cholec.	Divert.	Pancr.	Mean	Micro	Macro	
OASST*	82.0	48.0	45.5	44.1	54.9	-	-	-
SFT-all	98.4	89.8	95.8	87.5	92.8	93.6	92.9	\$3792.79
SM-DDPO ⁺	74.3	0.0	15.6	58.0	37.0	45.4	31.8	-
ReAct	90.2	79.7	66.7	62.9	74.9	79.1	74.8	\$1480.32
LA-CDM (ZS)	73.5	55.1	72.0	57.5	64.5	65.3	64.5	\$1521.73
LA-CDM	93.1	83.6	75.0	73.5	81.3	84.1	81.3	\$1295.61



결과가 주장하는 것

- ▶ LA-CDM mean accuracy 81.3, macro F1 81.3
- ▶ ReAct보다 높은 성능과 낮은 평균 test cost
- ▶ training 후 confidence calibration도 개선

Uncertainty-Guided Latent Diagnostic Trajectory Learning for Sequential Clinical Diagnosis

LDTL

arXiv 2026

LDTL: 문제 제기

1. LLM 진단은 test selection을 명시적으로 모델링하지 못함

LLM 기반 diagnostic system은 진단을 생성할 수는 있지만, 실제 임상 경로처럼 어떤 test를 어떤 순서로 선택해야 하는지를 명시적으로 모델링하지 못한다.


2. Terminal reward만으로는 trajectory 학습이 부족함

terminal reward로 성능과 비용을 최적화하는 방식은 **diagnostic trajectory의 구조나 분포**를 직접 제어하지 못한다. 따라서 제한된 clinical trajectories에서 불안정하고, 어떤 path가 바람직한지에 대한 supervision이 약하다.

LDTL의 문제 설정

그래서 LDTL은 test selection을 **Latent Diagnostic Trajectory Learning** 문제로 두고, 단순 reward가 아니라 diagnostic improvement 기반의 action signal을 만들려고 한다.

LDTL: Main Figure



Agent 역할

Teacher agent: latent trajectory에서 action-wise diagnostic improvement signal을 만든다.

Student agent: teacher signal을 이용해 test selection policy를 학습한다.

LDTL: ideal vs. approximation

Ideal: trajectory posterior

$$q(z \mid h_0, y) = \frac{\exp(\beta S(z))}{\sum_{z' \in Z(h_0)} \exp(\beta S(z'))}$$

$$q(a_t \mid h_t, y) = \sum_{z: z_t = a_t} q(z \mid h_0, y)$$

trajectory z	$S(z)$	$q(z)$
(A, B, C)	3.0	0.30
(A, C, B)	2.0	0.12
(B, A, C)	2.5	0.20
(B, C, A)	3.5	0.35
(C, A, B)	1.0	0.02
(C, B, A)	0.5	0.01

$$q(A) = 0.42, \quad q(B) = 0.55, \quad q(C) = 0.03$$

전체 trajectory score $S(z)$ 로 posterior를 만든 뒤, 같은 action으로 시작하는 trajectory들의 probability를 합쳐 action posterior를 얻는다.

Approx.: one-step IG

$$IG(h_0, a) = \log p(y \mid h_0 + a) - \log p(y \mid h_0)$$

$$q(a \mid h_0, y) \propto \exp(IG(h_0, a)/\tau)$$

action	one-step IG
A	0.70
B	0.50
C	0.10

$$IG(A) > IG(B) > IG(C)$$

실제 학습에서는 전체 trajectory를 직접 열거하지 않고, 현재 state에서 action 하나를 추가했을 때의 diagnostic improvement로 action posterior를 만든다.

LDTL: 방법

Stage 1. Diagnostic LLM을 먼저 학습

full patient information, 즉 complete diagnostic results가 주어졌을 때 correct disease label을 예측하고 confidence score를 출력하도록 diagnostic LLM을 SFT한다.

Stage 2. Diagnostic LLM은 freeze하고 planner를 학습

학습된 diagnostic LLM을 고정한 뒤, planning LLM이 어떤 diagnostic action을 선택할지 학습한다. 각 step에서 action을 넣어본 뒤 **diagnostic improvement**로 action-level posterior $q(a_t | h_t, y)$ 를 만들고, planner policy를 여기에 맞춘다.

$$\mathcal{L}_{\text{planner}} = \sum_{t=1}^T \text{KL}(q(a | h_t, y) \parallel \pi_{\theta}(a | h_t))$$

핵심

정답 trajectory를 직접 만들지 않고, **freeze된 diagnostic LLM의 probability 변화**를 이용해서 planner supervision을 만든다.

LDTL: 결과와 의미

Method	Acc	Macro-F1	App.	Chol.	Div.	Pan.
RS	84.8	83.7	82.8	85.4	90.4	85.2
w/o LP	88.6	88.5	94.8	90.7	80.7	78.7
LDTL	93.4	91.7	98.9	95.4	78.8	87.9




Figure 4: Distribution of diagnostic termination steps

결과 해석

Table 2: LDTL이 RS, w/o LP보다 Acc와 Macro-F1에서 높다. 즉, latent trajectory supervision이 최종 진단 성능 개선으로 이어진다.

Figure 4: LDTL은 1-step 종료율이 많고 3-step 종료율이 적다. 필요한 정보를 더 빨리 모으고, 불필요한 추가 검사를 줄이는 방향으로 학습된다는 의미다.

Learning What Matters: Criticality-Guided Reinforcement Learning for Sequential Clinical Diagnosis

SIFT

Preprint 2026

SIFT: 문제 제기

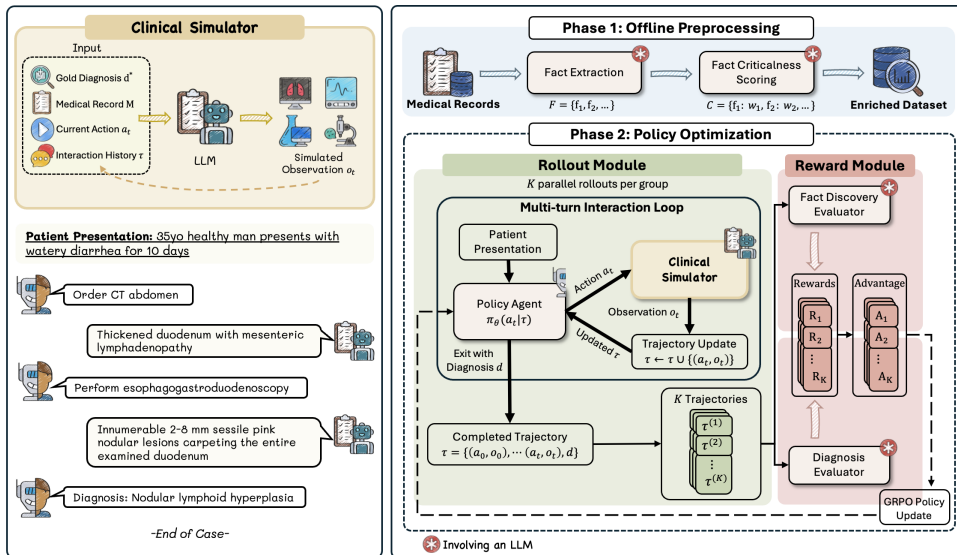
Terminal reward는 evidence quality를 보지 못함

최종 diagnosis가 맞았는지는 알려주지만, trajectory가 모은 evidence가 좋은지는 말해주지 않는다. 그래서 policy가 critical finding과 noise를 구분하지 못하고 **indiscriminate information acquisition**으로 흐를 수 있다.

SIFT의 문제 설정

정답 path를 직접 만들기보다, trajectory가 **critical evidence**를 얼마나 회수했는지를 reward signal로 만든다.

SIFT: Main Figure



구성요소

Critical evidence scorer: diagnosis에 중요한 evidence를 sentence-level로 표시한다.

Reward shaping: critical evidence 회수를 중간 reward로 바꿔 test selection을 학습한다.

SIFT: 사전 criticality scoring

EXAMPLE (illustrative only)

ACTION_HISTORY:

```
[
  {
    "action": "Order comprehensive metabolic panel",
    "result": "Lipase returned at 1200 U/L. ALT is 85 U/L."
  },
  {
    "action": "Ask about alcohol use",
    "result": "Patient denies alcohol use."
  }
]
```

FACT_LIST:

```
[
  "Lipase 1,200 U/L",
  "ALT 85 U/L",
  "AST 72 U/L",
  "No alcohol use"
]
```

Output:

discovered_fact_indices: [0,1,3]

1. Fact extraction

Training 전에 patient record M 에서 atomic clinical facts를 추출한다.

$$F = \phi(M) = \{f_1, \dots, f_n\}$$

각 f_i 는 lab value, imaging finding, physical exam result처럼 해석이 섞이지 않은 단일 observation이다.

2. Criticality scoring

$$w_f = \psi(f \mid d^*, o_0), \quad w_f \in \{0, 1, 2, 3\}$$

gold diagnosis d^* 와 initial presentation o_0 기준으로 각 fact가 얼마나 diagnosis를 confirm하는지 점수화한다.

Score meaning

- ▶ 0: diagnosis와 무관
- ▶ 1: supportive but non-specific evidence
- ▶ 2: significant evidence
- ▶ 3: hallmark / pathognomonic finding

Scoring은 offline으로 수행되어 rollout 중 ψ 를 호출하지 않는다.

SIFT: 방법

1. 왜 terminal reward만으로 부족한가

최종 diagnosis가 맞았는지만 보는 binary reward는 episode 끝에서만 관측된다. 어떤 action이 correct diagnosis에 기여했는지 알려주지 못하고, agent가 진단적으로 무관한 정보까지 넓게 수집하는 방향으로 흐를 수 있다.

2. Critical recall

Trajectory가 회수한 critical facts의 비율을 측정한다.

$$CR(\tau) = \frac{\sum_{f \in D(\tau)} w_f}{\sum_{f \in F} w_f}$$

F : 전체 fact set, $D(\tau)$: 발견된 fact set, w_f : criticality score.

3. Criticality-weighted reward

정답 여부와 critical evidence 회수를 같이 reward에 반영한다.


$$R(\tau) = \underbrace{(\alpha CR(\tau) + \beta) \text{acc}(\hat{d}, d^*)}_{\text{정답 보상}} + \underbrace{\eta CR(\tau)}_{\text{partial credit}} - \underbrace{\lambda \frac{t}{T}}_{\text{step penalty}}$$

- ▶ **정답 보상**: 정답이면 기본 보상 β , $CR(\tau)$ 만큼 $\alpha CR(\tau)$ 추가. 오답이면 이 항은 0
- ▶ **Partial credit**: 오답이어도 critical evidence를 많이 찾으면 $\eta CR(\tau)$ 보상
- ▶ **Step penalty**: 검사 step을 많이 쓸수록 감점. t : 사용 step, T : 최대 step

기존 방법들의 접근




문제점: 마지막에 맞췄지만 보고 그 path의 확률을 올리면
어떤 step이 좋았는지 알 수 없다.



full information으로
diagnostic LLM 학습

한 step 추가 시
정답 confidence 상승 학습



trajectory $\tau = \{(a_t, o_t)\}$ 안에서
critical facts를 얼마나 회수했는지 측정

예시: 검사 가치는 현재 state에 따라 달라진다

Box 1. Definitions of key terms (based on the 2012 Atlanta Classification of Acute Pancreatitis¹⁰)

Diagnosis of acute pancreatitis (2 of the following)

- Abdominal pain (acute onset of a persistent, severe, epigastric pain often radiating to the back)
- Serum lipase activity (or amylase) at least 3 times greater than the upper limit of normal
- Characteristic findings of acute pancreatitis on computed tomography or magnetic resonance imaging

핵심점:
3개 기준 중
2개 이상이면 진단

Source: Greenberg et al., "Clinical practice guideline: management of acute pancreatitis," Canadian Journal of Surgery (2016).

Appendicitis tests may include:

blood tests alone으로는
충수염 진단 불가

- **Blood tests** to look for signs of infection and inflammation that may mean you have appendicitis. But blood tests can't diagnose appendicitis.
- **A urine (pee) test** to rule out a **urinary tract infection** and/or a **kidney stone**. These conditions can cause symptoms similar to appendicitis.
- **Imaging tests** to take pictures of your appendix. If your symptoms and other tests suggest that you have appendicitis, imaging tests can confirm the diagnosis.

증상/진찰 소견이 있을 때
imaging으로 확정

Source: MedlinePlus, U.S. National Library of Medicine, "Appendicitis Tests" (2023).

LA-CDM은 왜 RL을 선택했나?

Training Efficient Clinical Action Selection At the core of training clinical decision-making lies the training of clinical action selection. During interaction with the clinical decision-making environment the model can freely choose to iteratively request any number of tests in any order. Given the vast number of possible diagnostic pathways, defining an optimal test sequence for each patient is infeasible, we therefore do not have a ground truth on which tests to perform. To still be able to train clinical decision-making, we propose to use reinforcement learning, where the model can learn through trial-and-error which tests are useful in which situations. Equal to the confidence

핵심

좋은 diagnostic path에 대한 직접적인 supervision은 없다. 그래서 LA-CDM은 최종 진단 정확도와 검사 비용을 reward로 두고, 여러 trajectory를 trial-and-error로 시도하면서 test-selection policy를 학습한다.

LA-CDM 한계점

ical agents (Bani-Harouni et al., 2025b), reward-driven optimization alone does not provide explicit control over the structure of diagnostic trajectories. In particular, learning purely from terminal rewards does not regulate how diagnostic paths are distributed in the latent reasoning space, and can be unstable in settings where only limited clinical trajectories are available for training.

The closest training effort, Bani-Harouni et al. [2026], trains a two-agent system on MIMIC-CDM with supervised fine-tuning and GRPO, combining terminal accuracy with test-cost penalties. Yet both the action space and the label space remain predefined and closed, and the reward provides no signal on the quality of evidence gathered along the way. This gap leaves open the question of

핵심

- ▶ LA-CDM은 여러 trajectory를 샘플링한 뒤, 최종 진단 정확도와 검사 cost의 trade-off로 좋은 path의 확률을 올린다.
- ▶ 하지만 reward는 전체 path에 주어지기 때문에, 어떤 중간 action이 실제로 진단을 바꿨는지 분리하기 어렵다.
- ▶ 특히 A 검사 이후에만 B 검사의 가치가 커지는 경우처럼, action 조합의 효과를 명시적으로 supervision하지 못한다.

감사합니다