

MIMIC-CDM 기반 Sequential Clinical Diagnosis 연구 동향

Path Supervision과 Stopping 문제를 중심으로


하서준

DGIST

2026년 5월 22일

LA-CDM · LDTL · SIFT · CaRT · MIMIC-CDM

Survey Map



최근에 생긴 문제 세팅

MIMIC-CDM (2024)이 **sequential evidence acquisition**을 benchmark로 만들면서, LLM diagnosis가 “full information classification”에서 “어떤 검사를 언제 볼 것인가”를 학습하는 문제로 이동했다.

오늘의 중점 주제

좋은 trajectory가 무엇인가?

정답 diagnosis label은 있지만 **좋은 diagnostic path label은 없다**. 그래서 최근 연구들은 좋은 trajectory를 직접 관측하지 못한 상태에서, 각자 다른 proxy로 이 빈칸을 메우고 있다.

- ▶ **LA-CDM**: 정확도와 검사 비용을 최적화하는 RL
- ▶ **LDTL**: 전체 trajectory를 우리가 모르는 latent로 두고, one-step information gain으로 근사
- ▶ **SIFT**: 중간 검사에 보상을 주어 좋은 검사를 많이 회수했는지 강화학습

MIMIC-CDM 데이터셋

Benchmark 목적

환자에게 모든 정보가 한 번에 주어지는 classification 문제가 아니라, **검사를 순차적으로 선택**하면서 diagnosis를 맞히는 clinical decision-making benchmark를 만든다.

규모와 label

총 **2,400명**의 abdominal disease 환자 사례.

Disease list

- ▶ appendicitis
- ▶ cholecystitis
- ▶ diverticulitis
- ▶ pancreatitis

Action space: 12 actions

- | | |
|---|-----------|
| 1. Lab tests | 7 actions |
| Complete Blood Count, Basic Metabolic Panel, Comprehensive Metabolic Panel, Renal Function Panel, Liver Function Panel, Urinalysis, Electrolyte Panel | |
| 2. Imaging reports | 4 actions |
| CT, MRI, Radiograph, Ultrasound | |
| 3. Physical examination | 1 action |

일부 환자에서는 특정 검사 결과가 기록되지 않은 경우가 있다.

Language Agents for Hypothesis-driven Clinical Decision Making with Reinforcement Learning

LA-CDM

ICLR 2026

LA-CDM: 문제 제기

1. 기존 clinical RL은 주로 tabular data만 고려함

기존 reinforcement learning 기반 clinical decision-making은 주로 **tabular data**에 맞춰져 있다. 그래서 clinical notes, imaging reports처럼 실제 진단에서 중요한 modality를 놓친다.


2. 기존 LLM clinical decision-making은 대부분 zero-shot임

기존 LLM 기반 clinical decision-making은 prompting이나 zero-shot reasoning에 의존한다. 즉, **diagnostic test selection**과 **sequential decision-making 자체를 명시적으로 학습**하지 않는다.

LA-CDM의 문제 설정

그래서 LA-CDM은 multimodal patient state에서 test를 순차적으로 요청하고, confidence가 충분할 때 diagnosis를 내리는 LLM-based clinical decision-making 문제를 제시한다.

LA-CDM: Main Figure




구성요소

Hypothesis: 현재까지 얻은 patient state를 바탕으로 가능한 diagnosis 후보를 유지한다.

Decision agent: 다음 test를 요청하거나, 충분한 confidence가 있으면 최종 diagnosis를 선택한다.

LA-CDM: 방법



Cyclic training objectives

1. Hypothesis generation

HA가 각 state에서 정답 diagnosis y_{true} 를 생성하도록 SFT.

2. Uncertainty-awareness

confidence가 $J(h_j) = \mathbb{I}[h_j = y_{\text{true}}]$ 에 맞도록 GRPO calibration.

3. Efficient action selection

DA가 필요한 test와 stop/diagnosis를 GRPO로 학습.

DA phase reward



$$R_{\text{diag}} = \begin{cases} r_{\text{pos}} & y_{\text{pred}} = y_{\text{true}} \\ r_{\text{neg}} & y_{\text{pred}} \neq y_{\text{true}} \\ r_{\text{invalid}} & \text{format error} \end{cases}$$

$$R_{\text{cost}}(T) = - \sum_{t_j \in T} c(t_j)$$

이 reward는 **efficient action selection phase**에서만 쓰인다. Hypothesis SFT와 confidence calibration은 별도 objective로 cycle 안에서 번갈아 학습된다.

LA-CDM: 결과와 의미

Method	Accuracy					F1-Score		Avg. Test Cost
	Append.	Cholec.	Divert.	Pancr.	Mean	Micro	Macro	
OASST*	82.0	48.0	45.5	44.1	54.9	-	-	-
SFT-all	98.4	89.8	95.8	87.5	92.8	93.6	92.9	\$3792.79
SM-DDPO ⁺	74.3	0.0	15.6	58.0	37.0	45.4	31.8	-
ReAct	90.2	79.7	66.7	62.9	74.9	79.1	74.8	\$1480.32
LA-CDM (ZS)	73.5	55.1	72.0	57.5	64.5	65.3	64.5	\$1521.73
LA-CDM	93.1	83.6	75.0	73.5	81.3	84.1	81.3	\$1295.61



결과가 주장하는 것

- ▶ LA-CDM mean accuracy 81.3, macro F1 81.3
- ▶ ReAct보다 높은 성능과 낮은 평균 test cost
- ▶ training 후 confidence calibration도 개선

Uncertainty-Guided Latent Diagnostic Trajectory Learning for Sequential Clinical Diagnosis

LDTL

arXiv 2026

LDTL: 문제 제기

1. LLM 진단은 test selection을 명시적으로 모델링하지 못함

LLM 기반 diagnostic system은 진단을 생성할 수는 있지만, 실제 임상 경로처럼 어떤 test를 어떤 순서로 선택해야 하는지를 명시적으로 모델링하지 못한다.


2. Terminal reward만으로는 trajectory 학습이 부족함

terminal reward로 성능과 비용을 최적화하는 방식은 diagnostic trajectory의 구조나 분포를 직접 제어하지 못한다. 따라서 제한된 clinical trajectories에서 불안정하고, 어떤 path가 바람직한지에 대한 supervision이 약하다.

LDTL의 문제 설정

그래서 LDTL은 test selection을 Latent Diagnostic Trajectory Learning 문제로 두고, 단순 reward가 아니라 diagnostic improvement 기반의 action signal을 만들려고 한다.

LDTL: Main Figure



Agent 역할

Teacher agent: latent trajectory에서 action-wise diagnostic improvement signal을 만든다.

Student agent: teacher signal을 이용해 test selection policy를 학습한다.

LDTL: ideal vs. approximation

Ideal: trajectory posterior

$$q(z \mid h_0, y) = \frac{\exp(\beta S(z))}{\sum_{z' \in Z(h_0)} \exp(\beta S(z'))}$$

$$q(a_t \mid h_t, y) = \sum_{z: z_t = a_t} q(z \mid h_0, y)$$

trajectory z	$S(z)$	$q(z)$
(A, B, C)	3.0	0.30
(A, C, B)	2.0	0.12
(B, A, C)	2.5	0.20
(B, C, A)	3.5	0.35
(C, A, B)	1.0	0.02
(C, B, A)	0.5	0.01

$$q(A) = 0.42, \quad q(B) = 0.55, \quad q(C) = 0.03$$

전체 trajectory score $S(z)$ 로 posterior를 만든 뒤, 같은 action으로 시작하는 trajectory들의 probability를 합쳐 action posterior를 얻는다.

Approx.: one-step IG

$$IG(h_0, a) = \log p(y \mid h_0 + a) - \log p(y \mid h_0)$$

$$q(a \mid h_0, y) \propto \exp(IG(h_0, a)/\tau)$$

action	one-step IG
A	0.70
B	0.50
C	0.10

$$IG(A) > IG(B) > IG(C)$$

실제 학습에서는 전체 trajectory를 직접 열거하지 않고, 현재 state에서 action 하나를 추가했을 때의 diagnostic improvement로 action posterior를 만든다.

LDTL: 방법

Stage 1. Diagnostic LLM을 먼저 학습

full patient information, 즉 complete diagnostic results가 주어졌을 때 correct disease label을 예측하고 confidence score를 출력하도록 diagnostic LLM을 SFT한다.

Stage 2. Diagnostic LLM은 freeze하고 planner를 학습

학습된 diagnostic LLM을 고정한 뒤, planning LLM이 어떤 diagnostic action을 선택할지 학습한다. 각 step에서 action을 넣어본 뒤 **diagnostic improvement**로 action-level posterior $q(a_t | h_t, y)$ 를 만들고, planner policy를 여기에 맞춘다.

$$\mathcal{L}_{\text{planner}} = \sum_{t=1}^T \text{KL}(q(a | h_t, y) \| \pi_{\theta}(a | h_t))$$

핵심

정답 trajectory를 직접 만들지 않고, **freeze된 diagnostic LLM의 probability 변화**를 이용해서 planner supervision을 만든다.

LDTL: 결과와 의미

Method	Acc	Macro-F1	App.	Chol.	Div.	Pan.
RS	84.8	83.7	82.8	85.4	90.4	85.2
w/o LP	88.6	88.5	94.8	90.7	80.7	78.7
LDTL	93.4	91.7	98.9	95.4	78.8	87.9




Figure 4: Distribution of diagnostic termination steps

결과 해석

Table 2: LDTL이 RS, w/o LP보다 Acc와 Macro-F1에서 높다. 즉, latent trajectory supervision이 최종 진단 성능 개선으로 이어진다.

Figure 4: LDTL은 1-step 종료 that 많고 3-step 종료 that 적다. 필요한 정보를 더 빨리 모으고, 불필요한 추가 검사를 줄이는 방향으로 학습된다는 의미다.

Learning What Matters: Criticality-Guided Reinforcement Learning for Sequential Clinical Diagnosis

SIFT

Preprint 2026

SIFT: 문제 제기

1. 기존 benchmark는 action과 diagnosis를 닫힌 공간으로 제한함

AMIE, ED-Copilot, LA-CDM 계열은 action space를 predefined test menu로 제한하고, diagnosis space도 fixed label set으로 둔다. 반면 실제 clinical reasoning은 open-ended interaction에 가깝다.


2. Terminal reward는 evidence quality를 보지 못함

최종 diagnosis가 맞았는지는 알려주지만, trajectory가 모은 evidence가 좋은지는 말해주지 않는다. 그래서 policy가 critical finding과 noise를 구분하지 못하고 **indiscriminate information acquisition**으로 흐를 수 있다.

SIFT의 문제 설정

정답 path를 직접 만들기보다, trajectory가 **critical evidence**를 얼마나 회수했는지를 reward signal로 만든다.

SIFT: Main Figure



구성요소

Critical evidence scorer: diagnosis에 중요한 evidence를 sentence-level로 표시한다.

Reward shaping: critical evidence 회수를 중간 reward로 바꿔 test selection을 학습한다.

SIFT: 사전 criticality scoring

EXAMPLE (illustrative only)

ACTION_HISTORY:

```
[
  {
    "action": "Order comprehensive metabolic panel",
    "result": "Lipase returned at 1200 U/L. ALT is 85 U/L."
  },
  {
    "action": "Ask about alcohol use",
    "result": "Patient denies alcohol use."
  }
]
```

FACT_LIST:

```
[
  "Lipase 1,200 U/L",
  "ALT 85 U/L",
  "AST 72 U/L",
  "No alcohol use"
]
```

Output:

discovered_fact_indices: [0,1,3]

1. Fact extraction

Training 전에 patient record M 에서 atomic clinical facts를 추출한다.

$$F = \phi(M) = \{f_1, \dots, f_n\}$$

각 f_i 는 lab value, imaging finding, physical exam result처럼 해석이 섞이지 않은 단일 observation이다.

2. Criticality scoring

$$w_f = \psi(f \mid d^*, o_0), \quad w_f \in \{0, 1, 2, 3\}$$

gold diagnosis d^* 와 initial presentation o_0 기준으로 각 fact가 얼마나 diagnosis를 confirm하는지 점수화한다.

Score meaning

- ▶ 0: diagnosis와 무관
- ▶ 1: supportive but non-specific evidence
- ▶ 2: significant evidence
- ▶ 3: hallmark / pathognomonic finding

Scoring은 offline으로 수행되어 rollout 중 ψ 를 호출하지 않는다.

SIFT: 방법

1. 왜 terminal reward만으로 부족한가

최종 diagnosis가 맞았는지만 보는 binary reward는 episode 끝에서만 관측된다. 어떤 action이 correct diagnosis에 기여했는지 알려주지 못하고, agent가 진단적으로 무관한 정보까지 넓게 수집하는 방향으로 흐를 수 있다.

2. Critical recall

Trajectory가 회수한 critical facts의 비율을 측정한다.

$$CR(\tau) = \frac{\sum_{f \in D(\tau)} w_f}{\sum_{f \in F} w_f}$$

F : 전체 fact set, $D(\tau)$: 발견된 fact set, w_f : criticality score.

3. Criticality-weighted reward

정답 여부와 critical evidence 회수를 같이 reward에 반영한다.

$$R(\tau) = \underbrace{(\alpha CR(\tau) + \beta) \text{acc}(\hat{d}, d^*)}_{\text{정답 보상}} + \underbrace{\eta CR(\tau)}_{\text{partial credit}} - \underbrace{\lambda \frac{t}{T}}_{\text{step penalty}}$$

- ▶ **정답 보상**: 정답이면 기본 보상 β , $CR(\tau)$ 만큼 $\alpha CR(\tau)$ 추가. 오답이면 이 항은 0
- ▶ **Partial credit**: 오답이어도 critical evidence를 많이 찾으면 $\eta CR(\tau)$ 보상
- ▶ **Step penalty**: 검사 step을 많이 쓸수록 감점. t : 사용 step, T : 최대 step

SIFT: 결과와 의미






Figure 2: Diagnostic accuracy versus evidence acquisition behavior for different policies. Each point represents a model or policy: the base model is the untrained Qwen3-32B, SIFT ($\eta=0$) and SIFT ($\eta=0.2$) are criticality-weighted reward variants, and Info Recall rewards the fraction of all facts discovered regardless of criticality.

Table 2: logistic regression that tests whether evidence quality (critical information, noise, and coverage) predicts diagnostic success, while controlling for differences between models and accounting for repeated evaluations on the same cases ($N = 324$).

Predictor	Coefficient	Std. Error	p-value
Critical info ratio	9.155	2.077	< 0.001
Noise ratio	-1.706	1.058	0.107
Info coverage	1.479	0.838	0.077
Model fixed effects		Included	

결과 해석: evidence의 양보다 critical evidence ratio가 diagnostic success를 가장 강하게 설명한다.

기존 방법들의 trajectory-level 접근




두 연구의 기본 가정

하나의 검사가 주는 정보량이 비교적 **독립적**이라고 본다. 즉, 어떤 검사 결과를 이미 알았다는 사실이 다른 검사를 추가했을 때의 예측 변화에 크게 영향을 주지 않는다고 가정하는 셈이다.


Greedy가 실패하는 이유는 중간 reward 부재가 아니다

Example 1: same second test C



Greedy는 $U(A) > U(B)$ 라서 A 를 고른다. 하지만 같은 C 를 붙이면 $B + C$ 가 더 높다.

Example 2: different second test



처음엔 A 가 더 좋아 보이지만, B 가 D 와 만나면 더 큰 trajectory utility를 만든다.

의미

중간 reward가 있어도 A , B 를 각각 따로 평가하면 A 가 더 좋아 보인다. 문제는 reward의 위치가 아니라, 한 검사의 가치가 **이후 어떤 검사와 결합되는지**에 따라 달라진다는 점이다.

그래서 어떻게?

1. Bayesian network

설명

검사 간 조건부 의존성을 명시적으로 모델링하고, evidence가 추가될 때 posterior를 업데이트한다.

장점

- ▶ 조합 효과와 redundancy를 원리적으로 다룰 수 있다
- ▶ query order를 probabilistic하게 정의할 수 있다

단점

- ▶ 자연어 report를 discrete variable로 바꾸기 어렵다
예: CT report → severe: yes/no로 줄이면 표현력이 감소

2. n -step lookahead training

설명

현재 검사 하나만 보지 않고, n step 뒤 가능한 조합의 utility를 미리 측정해 학습 신호로 쓴다.

장점

- ▶ 전체 subset을 다 label하지 않아도 된다
- ▶ 작은 조합의 synergy를 직접 학습시킬 수 있다

단점

- ▶ computational cost가 exponential하게 증가한다

Max step	Subsets	Coverage
1	12	0.29%
2	78	1.90%
3	298	7.28%
4	793	19.37%
5	1,585	38.71%
6	2,509	61.27%
7	3,301	80.61%
8	3,796	92.70%

감사합니다