

# Why Reasoning Fails to Plan

A Planning-Centric Analysis of Long-Horizon Decision Making in LLM Agents

하서준

DGIST

2026년 6월 4일

Reasoning  $\neq$  Planning · Lookahead · MCTS · FLARE

# **Why Reasoning Fails to Plan: A Planning-Centric Analysis of Long-Horizon Decision Making in LLM Agents**

Zehong Wang et al.

Preprint 2026


# 논문이 제기한 문제점

## 문제점

LLM reasoning은 step-wise local score가 높은 action을 고르는 경향이 있어, 긴 horizon에서는 초반 myopic choice가 회복하기 어려운 failure로 증폭된다.

## 논문의 해결 방향

Reasoning을 더 잘하게 만드는 것이 아니라, **미래 결과가 현재 action value로 되돌아오는 planning rule**을 넣어야 한다.



## Coherent planning의 3가지 필수 요건

### 1. Future evaluation

현재 action이 만드는 미래 trajectory를 평가

### 2. Value propagation


미래 outcome을 앞 action의 Q로 되돌려 반영

### 3. Limited commitment


전체 plan에 commit하지 않고 한 step 실행 후 replanning

# FLARE Framework Overview


## (a) The Overview of FALRE via Monte Carlo Tree Search



## (b) Expansion with Action Pruning



## (c) Trajectory-Level Evaluation with Trajectory Memory



## 핵심 구조

### Selection

UCB로 promising branch 선택

### Expansion

action pruning으로 후보 확장

### Simulation

후보 trajectory를 미리 rollout

### Back-propagation


trajectory value를 앞 action의 Q에 반영

현재 state를 root로 두고 이 과정을 반복한 뒤, **가장 높은 value의 action 하나만 실행**하고 다음 state에서 다시 계획한다.

## 방법: FLARE는 MCTS로 미래를 보고 한 step만 선택

Selection rule: 논문 수식 (7)


$$a_t = \arg \max_{a \in A(s_t)} \left[ \underbrace{Q(s_t, a)}_{\text{미래 rollout 결과가 누적된 action value}} + \underbrace{c}_{\text{탐색 강도 조절}} \underbrace{\sqrt{\frac{\log N(s_t)}{N(s_t, a) + 1}}}_{\text{덜 가본 action 선택 보너스}} \right]$$



### LLM이 하는 일

각 rollout trajectory를 독립적인 step 점수로 보지 않고, **trajectory 간 상대 가치**를 비교해서 return estimate를 만든다. 이 값이 backpropagation으로 앞 action의  $Q(s_t, a)$ 에 반영된다.

# 진단 Figure: step-wise decision은 왜 무너지는가



## 비교한 decision rule

### Single-step

현재 step의 local score가 가장 높은 action 하나만 선택

### Beam search

single-step 선택을 하나만 남기지 않고, 좋아 보이는 후보 path  $k$ 개를 동시에 탐색

### Lookahead

후보 action마다 짧은 미래 rollout을 보고 cumulative return 으로 선택

## Figure의 메시지

Single-step/beam은 horizon이 길어질수록 early trap에 commit하고 회복이 어렵다. Lookahead는 미래 결과를 보므로 trap 선택과 error accumulation을 줄인다.

## 아래 bar plot 지표

- ▶ **Trap select@step1**: 첫 action을 자유롭게 고를 때 trap을 선택한 비율
- ▶ **Success | force good@step1**: 첫 action을 좋은 action으로 고정했을 때 성공률
- ▶ **Success | force trap@step1**: 첫 action을 trap으로 고정했을 때 성공률

## 결과: accuracy **뿐** 아니라 planning behavior가 바뀜

**Table 3. Mechanism-level comparison of long-horizon planning behavior.** We report metrics that explicitly quantify decision dynamics, including trap selection at the first step, the average position of the first error, recovery probability after the first error, and the correct decision prefixes. Aggregated results across datasets show that FLARE improves all aspects of planning behavior, supporting more stable long-horizon decision-making. The complete breakdown is provided in Table 6.

| Method      | Constructed<br>Trap@1 ↓ | First-Error<br>Step ↑ | Recovery@<br>First-Error ↑ |
|-------------|-------------------------|-----------------------|----------------------------|
| Single Step | 55.6%                   | 1.6                   | 5.4%                       |
| Beam Search | 71.9%                   | 2.0                   | 11.4%                      |
| Lookahead   | 23.6%                   | 2.8                   | 22.4%                      |
| FLARE       | <b>17.8%</b>            | <b>3.2</b>            | <b>29.7%</b>               |

## 결과 해석

Single-step과 beam search는 local score에 묶여 초반 trap을 자주 선택하고, 한 번 벗어나면 거의 회복하지 못한다. Lookahead는 짧은 미래 평가로 trap을 줄이지만 효과가 제한적이다. FLARE는 trajectory outcome을  $Q$ 로 되돌려 반영하므로 **trap을 가장 적게 고르고, 오류를 더 늦추며, recovery도 가장 높다.**

## 핵심 지표

- ▶ **Trap@1**: 첫 선택에서 “당장은 좋아 보이지만 나중에 막히는 action”을 고른 비율
- ▶ **First-Error**: optimal path에서 처음 벗어나는 평균 step
- ▶ **Recovery**: 한 번 틀어진 뒤에도 다시 정답에 도달한 비율

# 그래서 어떻게?

## 1. Confidence agent 학습


다양한 evidence subset을 입력으로 주고, 그 subset만 보고 진단 confidence를 잘 내도록 학습한다.

목표: “현재까지 모은 정보로 얼마나 확신할 수 있는가”를 안정적으로 추정

## 2. Planner 학습

confidence agent는 고정하고, planner가 후보 action을 lookahead해본 뒤 어떤 검사를 할지 선택하도록 학습한다.

목표: 당장 그럴듯한 검사가 아니라, 이후 confidence를 가장 잘 개선하는 검사 선택



## 핵심

진단 모델을 매번 바꾸기보다, confidence를 평가하는 agent와 정보 획득을 계획하는 planner를 분리한다.