

Sequential Clinical Diagnosis

Two possible research directions

하서준

DGIST

2026년 6월 12일

Confidence Calibration · Lookahead Planner · LA-CDM Step-Level Reward

미팅 목적

논의하고 싶은 문제

Sequential clinical diagnosis에서 LLM agent가 **언제 어떤 검사를 요청하고, 언제 진단을 멈출지**를 더 잘 학습시키는 방법을 정리하고자 한다.

Direction 1
Confidence calibration first
supervised planner

Diagnostic Agent의 confidence를 먼저 보정하고, calibrated confidence를 이용해 lookahead teacher action을 만든다.


Direction 2
LA-CDM modification
step-level DA loss

LA-CDM rollout 구조는 유지하고, DA GRPO에 n -step future-aware reward를 추가한다.

핵심 질문

새로운 planner를 따로 학습할 것인가, 아니면 LA-CDM의 Decision Agent reward를 더 future-aware하게 바꿀 것인가?

Background: LA-CDM 구조




Training in LA-CDM

- ▶ HA SFT: partial state에서 ground-truth disease를 예측하도록 학습
- ▶ HA confidence GRPO: generated hypothesis가 맞았는지에 따라 confidence calibration
- ▶ DA GRPO: final diagnosis correctness와 test cost로 trajectory-level reward 부여

현재 한계

DA reward는 trajectory 하나당 scalar reward이므로, trajectory 내부에서 어떤 action이 언제 diagnostic confidence를 개선했는지에 대한 credit assignment가 약하다.

Direction 1: Calibrated DA + Supervised Planner



Idea

먼저 Diagnostic Agent가 partial evidence에서 disease hypothesis와 calibrated confidence를 안정적으로 내도록 만든다. 그 다음, candidate test를 lookahead로 평가해서 planner의 supervised target을 만든다.

Planner objective

$$\mathcal{L}_{plan} = -\log \pi_\phi(a_t^* \mid s_t, \hat{y}_t, c_t, \mathcal{A}_t)$$

Direction 1: Lookahead Teacher Construction

Candidate action evaluation

현재 state s_t 에서 후보 검사 a 를 실행했을 때의 future state를 training data 안에서 구성한다.

$$s_t^a = \text{Update}(s_t, a)$$

$$s_t^{a_1, a_2} = \text{Update}(\text{Update}(s_t, a_1), a_2)$$

State value from calibrated Diagnostic Agent

training 중에는 true disease y 를 알고 있으므로, future state의 diagnostic value를 다음처럼 둘 수 있다.

$$V(s) = p_\theta(y \mid s)$$

$$U(a_1, a_2) = V(s_t^{a_1, a_2}) - \lambda \{C(a_1) + C(a_2)\}$$

$$a_t^* = \arg \max_{a_1} \max_{a_2} U(a_1, a_2)$$

주의점

이 방식은 training-only oracle supervision에 가깝다. Inference에서는 unrevealed test result에 접근하지 않고, planner가 lookahead-derived policy를 imitate한다.

Direction 2: LA-CDM에 Step-Level Loss 추가

기존 LA-CDM DA GRPO

$$R_{\text{traj}} = R_{\text{diagnosis}} + R_{\text{format}} - \text{test cost}$$

same A_{traj} is applied to all DA tokens in the trajectory

문제

마지막에 맞춘 trajectory 전체의 확률은 올라가지만, **초반에 좋은 검사를 먼저 선택한 action**과 우연히 뒤에서 맞춘 action을 구분하기 어렵다.


Proposed change

기존 terminal trajectory advantage는 유지하되, 각 DA action a_t 에 대해 n -step 뒤 HA hypothesis/confidence 변화를 이용한 **step-level lookahead advantage**를 추가한다.

$$A_{i,t}^{\text{final}} = A_i^{\text{terminal}} + \alpha \cdot w_t \cdot A_{i,t}^{\text{lookahead}}$$

즉, 기존 LA-CDM의 안정적인 final diagnosis signal 위에 action별 credit assignment를 얹는다.

Direction 2: Trajectory Left-to-Right View



Value definition

$$V_t = \begin{cases} c_t, & h_t = y \\ -c_t, & h_t \neq y \\ 0, & \text{invalid hypothesis/confidence} \end{cases}$$

n -step diagnostic improvement reward

$$r_{i,t}^{lookahead} = V_{i,\min(t+n, T_i)} - V_{i,t} - \lambda C(a_{i,t})$$

$$A_{i,t}^{lookahead} = \frac{r_{i,t}^{lookahead} - \mu_{\text{group}}}{\sigma_{\text{group}} + \epsilon}$$

처음에는 같은 patient의 8 rollout에서 나온 모든 valid step reward를 하나의 group으로 묶어 normalize한다.

Direction 2: Proposed DA Loss

기존

$$\mathcal{L}_{DA} = -A_{\text{traj}} \sum_i \log \pi_{\theta}(x_i)$$

trajectory 안의 모든 DA token이 같은 advantage를 받는다.

변경

$$A_{i,t}^{\text{final}} = A_i^{\text{terminal}} + \alpha \cdot w_t \cdot A_{i,t}^{\text{lookahead}}$$
$$\mathcal{L}_{DA} = - \sum_{i,t} \sum_{k \in \mathcal{S}_{i,t}} [\rho_{i,k} A_{i,t}^{\text{final}} - \beta_{\text{KL}} D_{\text{KL},i,k}]$$

여기서 $\mathcal{S}_{i,t}$ 는 rollout i 의 step t 에서 생성된 DA token span이다.

Direction 2: Step Weighting

왜 step weight가 필요한가?

기존 LA-CDM은 final terminal reward로 만든 하나의 $A_i^{terminal}$ 을 trajectory 안의 모든 DA action token에 동일하게 적용한다. 따라서 첫 번째 검사, 두 번째 검사, 마지막 diagnosis action이 모두 같은 credit을 받는다. Step weighting은 이 uniform terminal credit 위에 **각 action의 temporal contribution**을 구분해서 엮기 위한 장치다.

Main proposal: position-aware step weight

$$w_t = \min\left(1, \frac{t+1}{K}\right)$$

$$A_{i,t}^{final} = A_i^{terminal} + \alpha \cdot w_t \cdot A_{i,t}^{lookahead}$$

예: $K = 3$ 이면 step 0은 0.33, step 1은 0.67, step 2 이후는 1.0의 lookahead signal을 받는다. 즉 terminal reward의 “모든 step 동일 credit”을 유지하되, 후속 evidence에 가까운 action일수록 더 직접적인 lookahead correction을 받도록 한다.

Ablation candidates

Uniform

$w_t = 1$: 모든 step에 같은 lookahead weight

Position-aware

$w_t = \min(1, (t+1)/K)$: terminal reward의 uniform credit을 step position에 따라 보정


Uncertainty

$w_t = 1 - c_t$: confidence가 낮을수록 action learning signal 증가

Direction 2: Token-Level Mapping

한 번의 rollout 후, 한 번의 backward

각 step마다 따로 역전파하지 않는다. Rollout 8개를 끝까지 만든 뒤, token 위치별 advantage matrix를 구성해서 기존 GRPO loss처럼 한 번에 업데이트한다.



Implementation view

$$\text{token_advantages} = \text{terminal_advantages}.\text{unsqueeze}(1) + \alpha \cdot \text{step_advantages}$$

step advantage는 해당 DA action token span에만 채우고, 나머지 위치에는 0을 둔다.

Two Directions: Comparison

	Direction 1	Direction 2
Main idea	Calibrated DA로 lookahead teacher를 만들고 planner를 supervised 학습	LA-CDM DA GRPO에 n -step future-aware reward 추가
Change size	큼: planner supervision pipeline 필요	작음: rollout 구조 유지, reward/loss 수정
Planning interpretation	명확한 explicit lookahead planning	lookahead-inspired credit assignment
Risk	teacher construction과 oracle supervision 설명 필요	HA confidence quality에 reward가 의존
First experiment	planner supervised imitation 성능 확인	terminal-only vs weighted step-level advantage ablation

현재 판단

시간과 구현 안정성을 고려하면 Direction 2를 먼저 실험하고, 효과가 있으면 Direction 1을 더 명시적인 planning extension으로 가져가는 전략이 현실적이다.

논의할 질문

1. 두 방향 중 우선순위를 어디에 둘 것인가?
2. confidence calibration이 충분히 안정적이라면, 이를 state value로 써도 되는가?
3. DA step-level lookahead reward는 어떤 형태가 좋은가?

$$V_{t+n} - V_t \quad \text{vs.} \quad \sum_{i=0}^{n-1} \gamma^i (V_{t+i+1} - V_{t+i})$$

4. final advantage는 다음 형태로 두는 것이 적절한가?

$$A_{i,t}^{final} = A_i^{terminal} + \alpha w_t A_{i,t}^{lookahead}$$

5. step weight w_t 는 어떤 방식이 좋은가?

$$w_t = 1 \quad \text{vs.} \quad w_t = \min(1, (t+1)/K) \quad \text{vs.} \quad w_t = 1 - c_t$$

6. 첫 ablation은 다음 정도로 충분한가?

- LA-CDM terminal-only
- terminal + uniform step lookahead
- terminal + position-aware step lookahead
- terminal + uncertainty-weighted step lookahead

Proposed Next Step

Implementation plan

1. Research2에서 LA-CDM rollout은 그대로 유지한다.
2. Trajectory에 DA step별 action token span을 저장한다.
3. HA hypothesis/confidence로 V_t 를 계산한다.
4. 각 action에 n -step diagnostic improvement reward를 부여한다.
5. 기존 terminal advantage에 weighted step advantage를 추가한다.

Recommended first setting

$$n = 2, \quad \alpha = 0.3, \quad K = 3, \quad w_t = \min(1, (t + 1)/K)$$

Rollout 수는 GRPO group comparison을 위해 기존처럼 8개를 유지한다. Terminal advantage는 유지하고, lookahead term만 position-aware weight로 추가한다.

Main contribution candidate

Sequential diagnosis에서 final outcome만 보는 trajectory-level RL이 아니라, HA confidence 변화에 기반한 **future-aware step-level credit assignment**를 도입한다.