

MCTS Lookahead 기반 검사 선택 Planner

Terminal Reward에서 Dense State-Action Value로

하서준

DGIST


2026년 6월 15일

LA-CDM · ORM/PRM · Confidence Calibration · MCTS Lookahead

핵심 질문

목표

현재 환자 state에서 다음 검사를 선택할 때, 단기적으로 그럴듯한 검사가 아니라 n -step 이후 진단 상태를 가장 많이 개선하는 검사를 학습하고 싶다.




핵심 관점

검사 선택은 reasoning 문제가 아니라 planning 문제다. 현재 action의 가치는 이후 검사들과의 조합, 중복성, stop timing에 의해 결정된다.

기존 방향: LA-CDM의 보상 구조

LA-CDM의 강점

LA-CDM도 exploration-exploitation 기반의 trial-and-error를 수행한다. 여러 진단 trajectory를 생성하고, 최종 진단 성공과 검사 비용을 통해 좋은 trajectory를 강화한다.



한계

최종 trajectory가 좋더라도, 그 안의 모든 검사가 실제로 좋은 것은 아니다. 즉, 어떤 검사 action이 진단 개선에 기여했는지에 대한 step-level supervision이 약하다.

ORM vs PRM 관점

ORM-like 최종 결과 중심 보상

- ▶ 최종 진단이 맞았는지 평가
- ▶ 검사 비용을 포함한 trajectory-level reward
- ▶ sparse signal
- ▶ action-level credit assignment가 약함

PRM-like 과정/행동 단위 value

- ▶ 현재 state-action의 미래 진단 가치 평가
- ▶ leaf value를 현재 action으로 backpropagation
- ▶ dense signal
- ▶ 검사별 기여도 분리 가능


정리

LA-CDM은 ORM-like terminal/trajectory reward에 가깝다. 제안 방향은 MCTS lookahead를 통해 PRM-like dense state-action value를 만들고, 이를 Planner 학습 신호로 사용한다.

왜 Planning인가?


Why Reasoning Fails to Plan의 관점

LLM의 step-wise reasoning은 현재 step에서 그럴듯한 선택을 잘 할 수 있지만, 장기 horizon에서는 local greedy decision에 머무르기 쉽다. Planning에는 다음 세 가지가 필요하다.



- ▶ **Explicit lookahead:** 후보 검사를 n -step까지 가상 진행하고 이후 진단 상태를 평가한다.
- ▶ **Backward value propagation:** 미래 진단 value를 현재 action의 가치로 되돌린다.
- ▶ **Limited commitment:** 전체 검사 sequence를 한 번에 실행하지 않고, 한 action만 선택한 뒤 다음 state에서 다시 planning한다.

제안 구조: 두 에이전트




핵심

Diagnosis + Confidence Agent는 value evaluator 역할을 하고, Planner Agent는 MCTS teacher가 선택한 action을 학습하는 student 역할을 한다.

Stage 1: Diagnosis + Confidence Agent


학습 목표

다양한 부분 환자 상태에서 진단을 맞추고, 그 진단에 대한 confidence를 calibration한다.



- ▶ 검사 결과를 일부 drop하여 다양한 partial state 생성
- ▶ Drop률을 0.1 → 0.8/0.9로 올리는 curriculum learning
- ▶ 진단 정확도와 confidence calibration을 함께 개선
- ▶ 수렴 후 freeze하여 Planner 학습의 evaluator로 사용

Stage 2: MCTS Lookahead




절차

현재 state를 root로 두고, 가능한 검사 12종 + Stop을 branch로 확장한다. Leaf state는 freeze된 Diagnosis + Confidence Agent로 평가하고, leaf value를 root action의 Q-value로 backpropagation한다.

MCTS에서 만드는 학습 신호

Leaf 평가

$$D_{\theta}(s_{\text{leaf}}) \rightarrow (h_{\text{leaf}}, c_{\text{leaf}})$$
$$R_{\text{leaf}} = \begin{cases} c_{\text{leaf}}, & h_{\text{leaf}} = y \\ -c_{\text{leaf}}, & h_{\text{leaf}} \neq y \\ 0, & \text{invalid state} \end{cases} \quad G_{\text{leaf}} = \gamma^d R_{\text{leaf}}$$




핵심

최종 trajectory reward만 주는 것이 아니라, 미래 진단 value를 현재 action의 $Q(s_t, a_t)$ 로 되돌려 **dense state-action supervision**을 만든다.

Planner 학습

MCTS teacher → Planner student

각 환자 state에서 MCTS가 root action별 Q-value를 계산한다. 가장 높은 Q-value를 가진 action을 pseudo-label로 사용해 Planner를 지도학습한다.



$$\mathcal{L}_{\text{planner}} = -\log \pi_{\phi}(a_t^* \mid s_t, h_t, c_t, A_t)$$

- ▶ A_t : 현재 가능한 검사 action set + Stop
- ▶ 학습 시에는 MCTS를 많이 사용하고, 추론 시에는 Planner가 바로 action 선택
- ▶ 즉, expensive search를 cheap policy로 distillation하는 구조

LA-CDM 대비 부각할 점

	LA-CDM	제안 방법
Reward granularity	최종 진단/비용 중심의 trajectory reward	미래 진단 value를 state-action으로 backpropagation
ORM/PRM 관점	ORM-like terminal feedback	PRM-like dense process/value supervision
Exploration	trial-and-error는 가능하지만 action별 기여도 분리가 약함	MCTS로 promising action을 더 깊게 탐색하고 value를 재사용
검사 조합효과	최종 trajectory 성공에 간접 반영	n -step lookahead로 검사 간 complementarity와 redundancy를 직접 반영
Stop decision	최종 보상으로 간접 학습	현재 stop value와 추가 검사 future value를 직접 비교

주장

두 방법 모두 trial-and-error를 하지만, 제안 방법은 future diagnostic outcome을 dense한 state-action value로 변환하므로 exploration이 더 효율적이고 action-level credit assignment가 명확하다.

우려사항과 검증 포인트

우려사항

- ▶ Diagnosis Agent와 Planner Agent 두 모델을 학습해야 함
- ▶ Confidence calibration 품질이 Planner 성능에 영향을 줄 수 있음
- ▶ MCTS hyperparameter H, S, γ 선택 필요
- ▶ MCTS teacher 생성 비용이 큼

검증 포인트


- ▶ Confidence calibration: ECE, Brier score
- ▶ Planner 성능: 최종 진단 정확도, 검사 수, 비용
- ▶ Action credit: 중복 검사 감소, 유용 검사 선택률
- ▶ Ablation: no lookahead, no backprop, no confidence

중요한 방어 논리

Confidence가 완벽할 필요는 없다. 최소한 정확도와 양의 상관관계를 가지며, calibration 개선이 Planner 성능 개선으로 이어지는지를 실험적으로 보이면 된다.

한 문장 요약

LA-CDM은 좋은 trajectory를 찾는 trial-and-error에 가깝고,
제안 방법은 각 검사 action의 장기적 진단 가치를
MCTS로 추정해 Planner에 distillation한다.



차별점

최종 결과만 보고 강화하는 것이 아니라, 미래 진단 value를 현재 검사 선택으로 되돌려 action-level supervision을 만든다.