

7/14 미팅

Dual-Channel Latent Communication for Clinical Diagnosis

하서준

DGIST

2026년 7월 14일

C2C · LCF · LR Agent · LoRA Cache Handoff

기존 latent communication은 대체로 하나의 매체를 선택한다


Table 1: Types of communicated information used by representative methods (✓ = yes).

Method	Embedding	Hidden State	KV-Cache	Other
CIPHER [Liu et al., 2024]	✓ (weighted)			
AC [Ye et al., 2025]		✓		
Interlat [Du et al., 2026]		✓		
SDE [Yang et al., 2025]				delta
KVComm [Wang et al., 2025a]			✓	
Cache-to-Cache [Liu et al., 2025b]			✓	
LatentMAS [Wang et al., 2025b]			✓	
ThoughtComm [Li et al., 2025]		✓		
Q-KVComm [Park et al., 2025]			✓ (comp.)	
LRAgent [Jeon et al., 2026]			✓ (base+lr)	
RelayCaching [Geng et al., 2026]			✓ (dec)	
Agent Memory [Shkolnikov, 2026]			✓ (Q4)	
Agent Primitives [Jin et al., 2026]			✓ (inter)	
Edge LLM Handover [Lee et al., 2026]			✓ (backhaul)	
Vision Wormhole [Liu et al., 2026b]				UVC
BIGMAS [Hao et al., 2026]				workspace
Mixture of Thoughts [Fein-Ashley et al., 2025]		✓ (proj.)		
Five Ws Survey [Chen et al., 2026]	(all)	(all)	(all)	(taxonomy)

기존 latent communication 연구들은 모두 embedding, hidden state, KV-cache 중 하나의 latent 매체만 선택해 넘겨왔다.
그러나 이들이 정말 같은 정보인가?

Latent communication에서 넘길 수 있는 신호 종류

어떤 latent를 넘기는지에 따라 의미가 달라진다



- ▶ **Hidden state**
현재 prefix를 처리한 compact representation. belief나 intent를 압축해 전달하기 좋지만, token-level evidence memory는 약하다.
- ▶ **KV cache**
attention에서 다시 참조할 수 있는 context memory. long evidence를 보존하지만, base memory와 role-specific signal이 섞인다.
- ▶ **Embedding**
token이 transformer block에 들어가기 전의 lexical input representation. 원문 token identity는 강하지만, reasoning 이후의 belief나 attention memory는 아직 담기지 않는다.

핵심: embedding은 입력 자체, hidden state는 compact belief, KV cache는 다시 참조 가능한 evidence memory에 가깝다.

왜 KV와 hidden state를 둘 다 넘기는가?

KV cache

- ▶ prompt와 patient evidence를 token-level로 다시 참조할 수 있는 cache
- ▶ 모델의 생각이 발전하면서 어떤 evidence를 누적했는지 보존
- ▶ attention 과정에서 어떤 부분에 집중했는지 반영
- ▶ planner가 필요한 증거 위치에 다시 cross-attend할 수 있음

역할

“무엇을 봤는가”를 담는
diagnostic evidence memory


Hidden state

- ▶ decode 직전 next-token prediction으로 이어지는 집약 representation
- ▶ 마지막 hidden state는 LM head를 거쳐 logits로 바로 변환
- ▶ disease posterior와 uncertainty를 compact하게 표현
- ▶ stop/add gate와 action policy에 직접 연결하기 쉬움

역할

“현재 무엇을 믿는가”를 담는
diagnostic belief state

구조: Dual Channel Latent Communication




LR Agent: 멀티 LoRA adapter 세팅에서 캐시를 공유해보자

multi-LoRA weight decomposition

$$W_i = W_0 + \Delta W_i = W_0 + A_i B_i$$

$$Y_i = X_i W_i = X_i W_0 + (X_i A_i) B_i$$



KV cache에 적용하면

$$V_i = V_{\text{base},i} + V_{\text{adapter},i}, \quad V_{\text{adapter},i} = (X_i A_i^V) B_i^V$$

- ▶ LR Agent는 base cache를 agent 간 공유하고, adapter output은 low-rank cache로 저장한다.
- ▶ 여기서 중요한 건 **full KV가 아니라 adapter-induced cache residual**을 따로 볼 수 있다는 점이다.

