

# 7/20 미팅

## HeteroMAS: Heterogeneous Agent를 위한 KV-Cache Communication

하서준

DGIST

2026년 7월 20일

LatentMAS · RecursiveMAS · Cache-to-Cache · HeteroMAS

# 이번 발표의 목적

## 비교할 기존 구조

- ▶ **LatentMAS**: training-free latent thought + KV working memory
- ▶ **RecursiveMAS**: inner/outer recursive link 기반 latent MAS
- ▶ **Cache-to-Cache**: pairwise LLM cache fusion

## 우리 구조

- ▶ heterogeneous role-specialized agents
- ▶ hidden state 전달 제거
- ▶ sender KV를 receiver-compatible prefix KV로 번역
- ▶ receiver KV와 fusion하지 않고 prepend



# LatentMAS의 한계: heterogeneous setting


## 논문 구조의 강한 가정

- ▶ 같은 모델 family 또는 같은 shape의 layer-wise KV를 전제로 하기 쉽다.
- ▶ 서로 다른 layer 수, KV head 수, head dimension에 대한 변환은 main method가 아니다.
- ▶ heterogeneous extension은 adapter가 필요하다는 future direction에 가깝다.




따라서 HeteroMAS에서는 “KV를 넘긴다”가 아니라, sender KV를 receiver가 읽을 수 있는 prefix KV로 번역해야 한다.

# RecursiveMAS overview



## RecursiveLink




# Cache-to-Cache: pairwise cache fusion



## C2C의 핵심 수식

$$C_F^n = C_R^n(X) + F_n\left(C_R^n(X), C_S^{G(n)}(X)\right)$$


$$y_{i+1} = P(y_i \mid C_F(X) \oplus C(Y_{0:i}))$$



C2C는 receiver가 이미 같은 input X를 prefill해서 만든 cache를 가지고 있고, 여기에 sharer cache를 residual하게 섞는 구조다.



# See What I See: dense heterogeneous KV alignment



## Phase 1: reconstruction

Sender와 receiver에 같은 프롬프트를 넣어 각각 KV를 만든다. Adapter는 sender KV를 receiver가 만들었을 KV처럼 맞추도록 학습한다.

## Phase 2: generation

맞춘 KV를 receiver의 past cache로 실제 주입한다. 이제 "모양만 비슷한 KV"가 아니라 답 생성에 도움이 되는 KV가 되도록 CE로 학습한다.

## 한계

Dense KV alignment는 강하지만, 기본 단위는 same-source-context cache translation이다. Role-conditioned latent thought handoff는 별도 문제로 남는다.



# C2C에서 fusion을 쓰는 이유

## 왜 receiver KV를 같이 보나?

- ▶ Sharer와 Receiver가 같은 context X를 인코딩한다.
- ▶ Receiver의 기존 이해를 보존해야 한다.
- ▶ Gate가 도움이 되는 layer만 선택한다.

## 우리 설정과 다른 점

- ▶ agent마다 role prompt와 objective가 다르다.
- ▶ Receiver KV를 만들려면 receiver prefill을 먼저 해야 한다.
- ▶ 우리는 receiver prefill 전에 prefix memory를 주입하고 싶다.

따라서 HeteroMAS는 C2C-style fusion이 아니라 **sender-only KV translation + prefix prepend**를 기본 구조로 둔다.


# 현재 Heterogeneous KV 연구들의 한계

## 무엇을 잘하나

- ▶ 서로 다른 모델의 KV cache shape을 맞춘다.
- ▶ sender cache를 receiver-native cache로 번역한다.
- ▶ text decode/re-encode 비용을 줄인다.

## 무엇이 빠져 있나

- ▶ sender가 role-conditioned **latent thought**를 생성하지 않는다.
- ▶ 같은 source context X의 cache alignment에 가깝다.
- ▶ MAS의 planner → refiner → solver handoff를 직접 모델링하지 않는다.



## 핵심 문제

기존 heterogeneous KV transfer는 “내가 본 context를 네 cache로 바꾼다”에 가깝고, 우리가 필요한 것은 “내가 agent role에서 생각한 latent state를 네 role의 communication slot으로 넘긴다”이다.