

1. LA-CDM

LA-CDM은 최종 diagnosis correctness와 test cost로 trajectory reward를 만든다.

$$R_{\text{diag}}(y_{\text{pred}}) = \begin{cases} r_{\text{pos}}, & y_{\text{pred}} = y_{\text{true}}, \\ r_{\text{neg}}, & y_{\text{pred}} \neq y_{\text{true}}, \\ r_{\text{invalid}}, & \text{out-of-format.} \end{cases}$$

$$R_{\text{cost}}(T) = - \sum_{t_j \in T} c(t_j), \quad R_{\text{traj}} = R_{\text{diag}} + R_{\text{cost}}.$$

GRPO는 rollout들을 비교해 trajectory-level signal을 만든다. LA-CDM은 이 signal을 trajectory 안의 모든 DA action token에 동일하게 적용한다.

$$A_i^{\text{traj}} \rightarrow \text{all DA action tokens in trajectory } i$$

즉, 좋은 trajectory 안에 있는 action들은 기여도와 관계없이 같은 방향으로 강화된다.

2. Step supervision

각 action 이후 confidence 수치가 2-step 뒤 얼마나 변했는지 계산한다.

$$c_{i,t} = \text{confidence score at step } t$$

$$R_{i,t}^{\text{step}} = c_{i,t+2} - c_{i,t}$$

2 step 뒤 상태가 없으면 trajectory의 마지막 상태를 사용한다. Step reward는 같은 trajectory 안에서 평균을 빼 action-level advantage로 변환한다. 이를 통해 같은 진단 경로 안에서 상대적으로 confidence를 더 많이 개선한 action에 더 큰 credit을 준다.

$$\bar{R}_i^{\text{step}} = \frac{1}{T_i} \sum_{t=1}^{T_i} R_{i,t}^{\text{step}} \quad A_{i,t}^{\text{step}} = R_{i,t}^{\text{step}} - \bar{R}_i^{\text{step}} \quad A_{i,t}^{\text{final}} = A_i^{\text{traj}} + \alpha A_{i,t}^{\text{step}}$$

$$A_{i,t}^{\text{final}} \rightarrow \text{only DA action tokens at step } t$$

즉, trajectory-level signal은 유지하되, action별 future confidence 변화에 따라 각 action token에 다른 signal을 준다.

3. 예시

confidence는 [0, 1] 범위로 scaling되어 있다고 가정한다.

Case	현재 c_t	미래 c_{t+2}	R^{step}
confidence 증가	0.4	0.8	+0.4
confidence 감소	0.7	0.5	-0.2
confidence 변화 없음	0.6	0.6	0.0

$$R^{\text{step}} = c_{t+2} - c_t$$

위 표는 raw step reward를 보여준다. 최종 update에는 trajectory 내부 평균을 뺀 step advantage를 사용한다.

예를 들어 $A_i^{\text{traj}} = 1.0$, $\alpha = 0.3$, $A_{i,t}^{\text{step}} = +0.4$ 라면,

$$A_{i,t}^{\text{final}} = 1.0 + 0.3 \times 0.4 = 1.12.$$

이 action은 같은 trajectory 안의 다른 action보다 더 강한 update를 받는다.